

Université Paris Cité
M1 Mathématiques, Modélisation et Apprentissage
Statistique

Estimation dans un problème inverse linéaire à variables cachées :

vraisemblance, algorithme EM
et analyse de l'erreur

Arthur Conche, Abdel Niang
Année universitaire 2025–2026

Responsable universitaire : Camille Pouchol

Remerciements

Résumé

Table des matières

Introduction	5
1 Mise en place du problème	6
1.1 Cadre général	6
1.2 Cas d'application	6
1.2.1 Cas 1 : translations en 1D	6
1.2.2 Cas 2 : rotations et projections en 2D	8
1.3 Simulation des données et premières observations numériques	10
2 Cas de référence : le modèle sans variables cachées	11
2.1 Modèle simplifié et estimateur du maximum de vraisemblance	11
2.2 Convexité et résolution exacte	12
2.3 Analyse de l'erreur d'estimation	12
2.4 Ce que ce cas enseigne sur le cas général	13
3 Formulation variationnelle et maximum de vraisemblance	15
3.1 Densité du couple (Y, Z) et vraisemblance marginale	15
3.2 Propriétés analytiques de la log-vraisemblance	16
3.3 Identifiabilité et choix d'une métrique adaptée	18
4 Résolution du problème d'optimisation	21
4.1 Descente de gradient directe	21
4.1.1 Rappel du gradient	21
4.1.2 Itération et choix du pas	21
4.1.3 Application au Cas 1	22
4.2 Algorithme Espérance-Maximisation (EM)	22
4.2.1 Log-vraisemblance des données complètes	22
4.2.2 Fonction auxiliaire Q	22
4.2.3 Étape E (Espérance)	23
4.2.4 Étape M (Maximisation)	23
4.2.5 Propriétés	24
4.3 Comparaison des deux approches	25
5 Analyse de la qualité de l'estimation	26
5.1 Retour au cas général avec variables cachées	26
5.2 Étude numérique de $\varepsilon_n(\sigma)$	27
6 Régularisation pour les problèmes inverses mal posés	30
6.1 Vraisemblance pénalisée	30

6.2	Régularisation de Tikhonov	31
6.3	Pénalités non quadratiques : ℓ^1 et variation totale	31
6.4	Interprétation spectrale	33
6.5	Choix du paramètre λ	33
6.6	Résultats numériques	33
7	Extensions	35
7.1	Cas 2 : rotations et projections en 2D	35
7.2	Étude numérique : reconstruction 2D oracle	39
	Conclusion	42

Introduction

La détermination de la structure tridimensionnelle des macromolécules biologiques : protéines, virus, complexes ribosomaux, est l'une des questions centrales de la biologie structurale moderne. Comprendre la géométrie précise d'une protéine, c'est comprendre son fonctionnement, ses interactions avec d'autres molécules, et ouvrir la voie à la conception rationnelle de médicaments. Depuis les années 2010, la *cryo-microscopie électronique* (cryo-EM) s'est imposée comme la technique de référence pour cette reconstruction, au point que ses pionniers, Jacques Dubochet, Joachim Frank et Richard Henderson, ont reçu le Prix Nobel de Chimie en 2017.

Le principe de la cryo-EM est le suivant. Des milliers de copies identiques de la molécule d'intérêt sont plongées dans une solution rapidement vitrifiée, si bien que chaque copie se fige dans une orientation aléatoire. Un faisceau d'électrons traverse l'échantillon et produit, pour chaque copie, une image bidimensionnelle : c'est la projection de la molécule selon l'axe du faisceau. L'observateur dispose donc de n images, chacune étant la projection d'une molécule ayant subi une rotation inconnue dans $SO(3)$, et fortement perturbée par le bruit de mesure inhérent à la technique. La question est alors : comment reconstruire la structure 3D originale à partir de ces projections bruitées dont les orientations sont toutes ignorées ?

Ce problème appartient à la classe des *problèmes inverses linéaires avec variables cachées*. Dans la modélisation mathématique, la structure moléculaire inconnue est représentée par un paramètre θ dans un espace fonctionnel approprié. Chaque rotation aléatoire Z_i , non observée, détermine un opérateur linéaire A_{Z_i} qui projette θ en une image bruitée $Y_i = A_{Z_i}\theta + \sigma E_i$. La difficulté fondamentale est double : il faut estimer θ sans connaître les Z_i , et la marginalisation sur ces variables cachées rend la vraisemblance non quadratique, invalidant les approches classiques des moindres carrés.

Ce rapport étudie ce problème dans deux cas simplifiés qui en capturent les difficultés essentielles. Le premier cas, en dimension 1, porte sur des translations aléatoires d'un signal périodique : il est analytiquement tractable et sert de terrain d'expérimentation pour tous les développements théoriques et numériques. Le second cas, en dimension 2, est l'analogue direct de la cryo-EM : des rotations aléatoires dans $\mathbb{R}^2$ suivies d'une projection, ce qui correspond à la transformée de Radon en deux dimensions.

Nous commençons par poser rigoureusement le cadre mathématique et les deux cas d'application (Section 1). Pour forger l'intuition, nous résolvons intégralement le problème simplifié où les transformations sont connues et constantes, ce qui fournit un estimateur explicite et une borne d'erreur de référence (Section 2). Nous formulons ensuite le problème de maximum de vraisemblance dans le cas général et mettons

en évidence une difficulté d'identifiabilité qui impose de reconsidérer la mesure d'erreur usuelle (Section 3). Deux algorithmes d'optimisation sont alors développés et comparés : une descente de gradient directe sur la log-vraisemblance et l'algorithme d'espérance-maximisation (EM), dont chaque itération se ramène à un problème quadratique convexe (Section 4). Nous analysons enfin quantitativement la précision de l'estimation en fonction du nombre de données n et du niveau de bruit σ , dans le cas avec variables cachées (Section 5), avant de présenter des extensions vers le cas des rotations en 2D et des approches de régularisation (Section 7).

1 Mise en place du problème

1.1 Cadre général

On dispose de n observations $Y_1, \dots, Y_n \in \mathbb{R}^p$ et l'on cherche à estimer un paramètre inconnu θ appartenant à E , espace de Hilbert de dimension finie muni du produit scalaire $\langle \cdot, \cdot \rangle$.

Soit $(\mathcal{Z}, \mathcal{F}, \mu)$ un espace mesuré. Pour chaque $z \in \mathcal{Z}$, on se donne un opérateur linéaire borné $A_z \in L(E, \mathbb{R}^p)$. Les observations suivent le modèle

$$Y_i = A_{Z_i} \theta + \sigma E_i, \quad i \in \{1, \dots, n\}, \quad (\text{M})$$

où $\sigma > 0$ est un niveau de bruit connu, et les variables aléatoires $(Z_i)_{1 \leq i \leq n}$ et $(E_i)_{1 \leq i \leq n}$ vérifient les hypothèses suivantes.

- Les $(Z_i)_{1 \leq i \leq n}$, à valeurs dans $\mathcal{Z}$, sont i.i.d. de densité f_Z par rapport à la mesure μ .
- Les $(E_i)_{1 \leq i \leq n}$, à valeurs dans $\mathbb{R}^p$, sont i.i.d. de loi $\mathcal{N}(0, \text{Id}_p)$.
- Les familles $(Z_i)_{1 \leq i \leq n}$ et $(E_i)_{1 \leq i \leq n}$ sont indépendantes.

Les variables (Z_i) jouent le rôle de *variables cachées* : elles déterminent quelle transformation linéaire A_{Z_i} est appliquée à θ avant observation, mais elles ne sont pas accessibles à l'observateur. Chaque Y_i est donc une version transformée et bruitée de θ , dont la transformation elle-même est inconnue. C'est cette double incertitude, sur θ et sur les Z_i , qui constitue la difficulté centrale du problème.

1.2 Cas d'application

1.2.1 Cas 1 : translations en 1D

Le premier cas d'application est celui des *translations sur le tore*. On note $\mathbb{T} = \mathbb{R}/2\pi\mathbb{Z}$ le tore unidimensionnel, que l'on identifie à l'intervalle $[0, 2\pi[$ muni de la mesure de Lebesgue. L'espace ambiant est $L^2(\mathbb{T})$, l'espace des fonctions de carré intégrable et

2π -périodiques, muni du produit scalaire

$$\langle f, g \rangle = \frac{1}{2\pi} \int_0^{2\pi} f(x) \overline{g(x)} dx.$$

Sous-espace E et discrétisation. On travaille avec un sous-espace de dimension finie d de $L^2(\mathbb{T})$, engendré par les premières harmoniques de Fourier :

$$E = \text{Vect} \left(x \mapsto e^{ikx}, -\frac{d-1}{2} \leq k \leq \frac{d-1}{2} \right),$$

où d est supposé impair pour que l'espace soit symétrique autour de la fréquence nulle. Tout $\theta \in E$ s'écrit donc comme un polynôme trigonométrique de degré au plus $\frac{d-1}{2}$. En pratique numérique, comme θ est à valeurs réelles, la condition $\hat{\theta}_{-k} = \overline{\hat{\theta}_k}$ permet de se ramener à la base réelle $\{1, \cos(kx), \sin(kx)\}_{k=1}^N$ (avec $N = (d-1)/2$) et de représenter θ par un vecteur de coefficients $u = (a_0, a_1, b_1, \dots, a_N, b_N)^\top \in \mathbb{R}^d$ via

$$\theta(x) = a_0 + \sum_{k=1}^N (a_k \cos(kx) + b_k \sin(kx)).$$

C'est cette paramétrisation réelle qu'on utilise dans les implémentations numériques.

Les observations sont effectuées sur une grille uniforme de $p \geq d$ points :

$$x_j = 2\pi \frac{j}{p}, \quad j \in \{0, \dots, p-1\}.$$

La condition $p \geq d$ garantit que l'évaluation sur la grille est injective sur E , ce qui est nécessaire pour l'identifiabilité du problème.

Opérateur de translation. L'espace des variables cachées est $\mathcal{Z} = [0, 2\pi[$ muni de la mesure de Lebesgue normalisée. Pour $z \in [0, 2\pi[$ et $\theta \in E$, l'opérateur $A_z \in L(E, \mathbb{R}^p)$ est défini par évaluation de la translatée de θ :

$$(A_z \theta)_j = \theta(x_j - z), \quad j \in \{0, \dots, p-1\},$$

où la soustraction $x_j - z$ est entendue modulo 2π . Autrement dit, $A_z \theta$ est le vecteur des valeurs de θ décalé de z sur la grille.

Remarque 1.1. Puisque $\theta \in E$ est un polynôme trigonométrique, sa translatée $x \mapsto \theta(x - z)$ appartient encore à E pour tout $z \in [0, 2\pi[$. L'opérateur A_z est donc bien défini et sa structure se lit aisément dans la base de Fourier : si $\theta = \sum_k \hat{\theta}_k e^{ikx}$, alors

$$(A_z \theta)_j = \sum_k \hat{\theta}_k e^{ik(x_j - z)} = \sum_k \hat{\theta}_k e^{-ikz} e^{ikx_j}.$$

La translation par z agit donc comme une modulation de phase dans l'espace de Fourier : le coefficient $\hat{\theta}_k$ est multiplié par e^{-ikz} .

Modèle dans le Cas 1. Le modèle (M) se spécialise ici en

$$Y_i = A_{Z_i}\theta + \sigma E_i \in \mathbb{R}^p, \quad (Y_i)_j = \theta(x_j - Z_i) + \sigma (E_i)_j,$$

où les Z_i sont i.i.d. de loi uniforme sur $[0, 2\pi[$, et les $(E_i)_j$ sont i.i.d. $\mathcal{N}(0, 1)$. Chaque observation Y_i est donc un échantillonnage bruité de θ sur la grille, après une translation aléatoire inconnue. L'objectif est de reconstruire θ à partir des n vecteurs $Y_1, \dots, Y_n$, sans connaître les décalages $Z_1, \dots, Z_n$.

Lien avec la cryo-EM. Ce cas constitue l'analogue unidimensionnel du problème de reconstruction moléculaire décrit en introduction. Le signal θ joue le rôle de la structure à reconstruire, la translation aléatoire Z_i simule l'orientation inconnue de la molécule, et la projection sur la grille correspond à l'acquisition d'une image discrétisée. Sa relative simplicité analytique, notamment la diagonalisation de A_z dans la base de Fourier, en fait le terrain naturel pour développer et valider les méthodes d'estimation étudiées dans ce rapport.

1.2.2 Cas 2 : rotations et projections en 2D

Le second cas d'application est celui des *rotations et projections en dimension 2*. Il constitue l'analogue bidimensionnel direct du problème de reconstruction en cryo-EM, et est étroitement lié à la tomographie par rayons X.

Espace fonctionnel. On note $B(0, 1) = \{(x, y) \in \mathbb{R}^2 : x^2 + y^2 \leq 1\}$ la boule unité euclidienne dans $\mathbb{R}^2$. L'espace ambiant est $L^2(B(0, 1))$, muni du produit scalaire

$$\langle f, g \rangle = \int_{B(0,1)} f(\mathbf{x}) \overline{g(\mathbf{x})} d\mathbf{x}.$$

Le paramètre inconnu $\theta \in E$, où E est un sous-espace de dimension finie d de $L^2(B(0, 1))$, représente la densité bidimensionnelle à reconstruire, l'analogue discret de la densité électronique d'une molécule.

Opérateur de rotation. L'espace des variables cachées est $\mathcal{Z} = [0, 2\pi[$ muni de la mesure de Lebesgue normalisée. Pour $z \in [0, 2\pi[$, on note R_z la rotation plane d'angle z , de matrice

$$R_z = \begin{pmatrix} \cos z & -\sin z \\ \sin z & \cos z \end{pmatrix}.$$

L'action de R_z sur une fonction $\theta \in L^2(B(0, 1))$ est définie par composition :

$$(R_z\theta)(\mathbf{x}) = \theta(R_z^{-1}\mathbf{x}) = \theta(R_{-z}\mathbf{x}), \quad \mathbf{x} \in B(0, 1).$$

Puisque R_z est une isométrie de $B(0, 1)$ dans lui-même, $R_z\theta$ est bien dans $L^2(B(0, 1))$ dès que θ l'est.

Opérateur de projection. On définit l'opérateur de projection $P : L^2(B(0, 1)) \rightarrow L^2([-1, 1])$ par intégration selon l'axe y :

$$(P\theta)(x) = \int_{\mathbb{R}} \theta(x, y) dy, \quad x \in [-1, 1].$$

Cet opérateur est la *transformée de Radon* de θ selon la direction verticale : il donne la somme (intégrale) de θ le long de chaque droite verticale $\{x\} \times \mathbb{R}$.

Remarque 1.2. La transformée de Radon complète de θ consiste à calculer $P(R_z\theta)$ pour tous les angles $z \in [0, \pi[$, ce qui correspond à projeter θ selon toutes les directions du plan. Le théorème de la tranche de Fourier établit que la transformée de Fourier 1D de $P(R_z\theta)$ en x coïncide avec la transformée de Fourier 2D de θ restreinte à la droite de direction z . C'est le fondement théorique des algorithmes de rétroprojection filtrée utilisés en tomographie.

Opérateur A_z et discrétisation. L'opérateur $A_z \in L(E, \mathbb{R}^p)$ combine la rotation et la projection :

$$A_z = \text{ev}_{\text{grille}} \circ P \circ R_z,$$

où $\text{ev}_{\text{grille}}$ désigne l'évaluation sur une grille uniforme de p points $x_j = j/p \in [0, 1]$, $j \in \{0, \dots, p-1\}$. Explicitement :

$$(A_z\theta)_j = (PR_z\theta)(x_j) = \int_{\mathbb{R}} \theta \left(R_{-z} \begin{pmatrix} x_j \\ y \end{pmatrix} \right) dy, \quad j \in \{0, \dots, p-1\}.$$

Chaque observation $(A_z\theta)_j$ est donc la valeur en x_j de la projection de θ après rotation d'angle z .

Modèle dans le Cas 2. Le modèle (M) se spécialise en

$$Y_i = A_{Z_i}\theta + \sigma E_i \in \mathbb{R}^p, \quad (Y_i)_j = \int_{\mathbb{R}} \theta \left(R_{-Z_i} \begin{pmatrix} x_j \\ y \end{pmatrix} \right) dy + \sigma (E_i)_j,$$

où les Z_i sont i.i.d. de loi uniforme sur $[0, 2\pi[$, et les $(E_i)_j$ sont i.i.d. $\mathcal{N}(0, 1)$. Chaque Y_i est un sinogramme partiel bruité de θ : c'est la projection de θ selon une direction

aléatoire inconnue, échantillonnée sur p points.

Comparaison avec le Cas 1. Le Cas 2 est structuellement plus proche du problème physique de départ que le Cas 1. Le groupe des variables cachées est le même ($[0, 2\pi[$ dans les deux cas), mais l'opérateur A_z est ici un opérateur intégral, la composition d'une rotation et d'une projection, là où il était simplement une évaluation décalée dans le Cas 1. La diagonalisation dans la base de Fourier n'est plus aussi directe, ce qui rend les développements analytiques plus délicats et les algorithmes d'estimation plus coûteux numériquement. Pour ces raisons, le Cas 2 sera traité principalement en Section 7, après que les méthodes aient été développées et validées sur le Cas 1.

1.3 Simulation des données et premières observations numériques

Génération d'une observation dans le Cas 1. Pour simuler une observation Y_i , on fixe d'abord le vecteur $u \in \mathbb{R}^d$ des coordonnées de θ dans la base trigonométrique réelle. On tire un Z_i à valeur dans $[0, 2\pi]$ et on évalue θ translatée de Z_i en chaque point de la grille $x_j = 2\pi \frac{j}{p}, j \in \{0, \dots, p-1\}$. On tire ensuite un vecteur de bruit gaussien $E_i \sim \mathcal{N}(0, \sigma \mathbf{Id}_p)$, et on observe $(Y_i)_j = \theta(x_j - Z_i) + (E_i)_j$.




FIGURE 1 – Influence des paramètres sur les observations simulées. Haut : effet du niveau de bruit σ . Bas : effet du nombre d'observations n .

2 Cas de référence : le modèle sans variables cachées

2.1 Modèle simplifié et estimateur du maximum de vraisemblance

On se place dans le cas simplifié où les transformations ne dépendent pas des variables cachées Z_i : on suppose $A_z = A$ pour tout $z \in \mathcal{Z}$, où $A \in L(E, \mathbb{R}^p)$ est un opérateur fixé. Le modèle (M) se réduit alors à

$$Y_i = A\theta + \sigma E_i, \quad i \in \{1, \dots, n\}. \quad (1)$$

Il s'agit d'un modèle linéaire gaussien : chaque observation Y_i est une version bruitée de $A\theta$, sans transformation cachée. On suppose de plus que $A^\top A$ est inversible, ce qui est équivalent à l'injectivité de A et constitue une condition nécessaire d'identifiabilité.

Densité et log-vraisemblance. Conditionnellement à θ , chaque Y_i suit la loi $\mathcal{N}(A\theta, \sigma^2 \text{Id}_p)$, de densité

$$p(y; \theta) = \frac{1}{(2\pi\sigma^2)^{p/2}} \exp\left(-\frac{\|y - A\theta\|^2}{2\sigma^2}\right).$$

Les observations étant i.i.d., la log-vraisemblance s'écrit

$$\ell_n(\theta) = -\frac{np}{2} \log(2\pi\sigma^2) - \frac{1}{2\sigma^2} \sum_{i=1}^n \|Y_i - A\theta\|^2.$$

Sa maximisation en θ est équivalente à la minimisation du critère des moindres carrés

$$F(\theta) = \sum_{i=1}^n \|Y_i - A\theta\|^2. \quad (2)$$

Estimateur du maximum de vraisemblance. En notant $\bar{Y}_n = \frac{1}{n} \sum_{i=1}^n Y_i$ la moyenne empirique, on décompose

$$F(\theta) = n \|\bar{Y}_n - A\theta\|^2 + \sum_{i=1}^n \|Y_i - \bar{Y}_n\|^2,$$

où le second terme ne dépend pas de θ (car $\sum_i (Y_i - \bar{Y}_n) = 0$). Minimiser F revient donc à minimiser $\|\bar{Y}_n - A\theta\|^2$, qui est convexe en θ , dont l'annulation du gradient donne les équations normales

$$A^\top A\theta = A^\top \bar{Y}_n.$$

Proposition 2.1. *Sous l'hypothèse que $A^\top A$ est inversible, le problème de maximum*

de vraisemblance associé au modèle (1) admet un unique maximiseur :

$$\hat{\theta}_n = (A^\top A)^{-1} A^\top \bar{Y}_n = \frac{1}{n} (A^\top A)^{-1} A^\top \sum_{i=1}^n Y_i. \quad (3)$$

Remarque 2.2. L'estimateur (3) est l'unique $\theta \in E$ tel que $A\theta$ soit le projeté orthogonal de $\bar{Y}_n$ sur $\text{Im}(A)$. En notant $A^\dagger = (A^\top A)^{-1} A^\top$ le pseudo-inverse gauche de A , on a simplement $\hat{\theta}_n = A^\dagger \bar{Y}_n$.

2.2 Convexité et résolution exacte

2.3 Analyse de l'erreur d'estimation

Erreur quadratique. Naturellement pour estimer la précision de notre estimateur des moindres carrés, on utilise l'erreur quadratique :

$$\epsilon_n^2 = \mathbb{E}_\theta \left[\left\| \hat{\theta}_n - \theta \right\|^2 \right].$$

On a

$$\begin{aligned} \hat{\theta}_n &= \frac{1}{n} (A^\top A)^{-1} A^\top \sum_{i=1}^n Y_i \\ &= \frac{1}{n} (A^\top A)^{-1} A^\top \sum_{i=1}^n (A\theta + \sigma E_i) \\ &= \theta + \frac{\sigma}{n} (A^\top A)^{-1} A^\top \sum_{i=1}^n E_i. \end{aligned}$$

Donc la variable aléatoire $\hat{\theta}_n - \theta$ suit une $\mathcal{N}(0, \frac{\sigma^2}{n} (A^\top A)^{-1})$.

Proposition 2.3. Soit W une variable aléatoire de loi $\mathcal{N}(\mu, \Sigma)$, alors

$$\mathbb{E}[\|W\|_2^2] = \text{Tr}(\Sigma) + \|\mu\|_2^2$$

Démonstration. On écrit $W = \mu + \varepsilon$ où $\varepsilon \sim \mathcal{N}(0, \Sigma)$, puis on développe :

$$\|W\|^2 = \|\mu + \varepsilon\|^2 = \|\mu\|^2 + 2\langle \mu, \varepsilon \rangle + \|\varepsilon\|^2.$$

En prenant l'espérance et en utilisant $\mathbb{E}[\varepsilon] = 0$:

$$\mathbb{E}[\|W\|^2] = \|\mu\|^2 + \mathbb{E}[\|\varepsilon\|^2].$$

Il reste à calculer $\mathbb{E}[\|\varepsilon\|^2]$. On utilise l'identité $\|\varepsilon\|^2 = \varepsilon^\top \varepsilon = \text{Tr}(\varepsilon \varepsilon^\top)$ et la linéarité de

la trace :

$$\mathbb{E}[\|\varepsilon\|^2] = \mathbb{E}[\text{Tr}(\varepsilon\varepsilon^\top)] = \text{Tr}(\mathbb{E}[\varepsilon\varepsilon^\top]) = \text{Tr}(\Sigma).$$

On conclut $\mathbb{E}[\|W\|^2] = \|\mu\|^2 + \text{Tr}(\Sigma)$. □

Corollaire 2.4. *L'erreur quadratique ϵ_n^2 s'écrit alors*

$$\epsilon_n^2 = \frac{\sigma^2}{n} \text{Tr}((A^\top A)^{-1})$$

2.4 Ce que ce cas enseigne sur le cas général

Le cas simplifié étudié dans cette section livre deux enseignements qui servent de référence pour la suite.

Ce que l'on retient. Quand l'opérateur est fixe ($A_z = A$ pour tout z), la log-vraisemblance est quadratique en θ et son maximum s'obtient par simple inversion de $A^\top A$. La formule $\epsilon_n^2 = \frac{\sigma^2}{n} \text{Tr}((A^\top A)^{-1})$ quantifie précisément le compromis entre le bruit σ , la géométrie de A (via la trace de son inverse de Gram) et le nombre de données n : l'erreur décroît en $1/\sqrt{n}$.

Ce qui change avec les variables cachées. Dès que A_z dépend de z , deux difficultés apparaissent simultanément.

Perte d'information par la moyenne. L'espérance d'une observation vaut

$$\mathbb{E}[Y_i] = \int_{\mathcal{Z}} A_z \theta \, d\mu(z) =: \bar{A} \theta,$$

où $\bar{A} = \int_{\mathcal{Z}} A_z \, d\mu(z)$. Dans le Cas 1 (translations uniformes sur le tore), ce calcul donne $(\bar{A} \theta)_j = \bar{\theta}$ pour tout j , où $\bar{\theta}$ est la moyenne de θ sur le tore : l'intégration sur les translations efface toute information de forme. La moyenne empirique $\bar{Y}_n$ converge donc vers un signal constant, et non vers $A \theta$. L'inversion directe de $\bar{A}$ ne peut pas restituer θ .

Non-quadraticité de la log-vraisemblance. La vraisemblance marginale s'obtient en intégrant sur les variables cachées :

$$p(Y_i; \theta) = \int_{\mathcal{Z}} \frac{1}{(2\pi\sigma^2)^{p/2}} \exp\left(-\frac{\|Y_i - A_z \theta\|^2}{2\sigma^2}\right) d\mu(z).$$

La log-vraisemblance $\ell_n(\theta) = \sum_{i=1}^n \log p(Y_i; \theta)$ est une somme de logarithmes d'intégrales exponentielles, une structure *log-sum-exp*, qui n'est plus quadratique en θ . Il n'existe pas de forme close pour son maximiseur, et les équations normales (2) n'ont plus d'analogue.

Perspectives. Ces deux obstacles motivent les algorithmes de la Section 4 : la descente de gradient sur ℓ_n , qui exploite sa différentiabilité, et l’algorithme EM, dont chaque itération se ramène, grâce aux données complètes, à un problème quadratique convexe analogue à (2). La formule $\epsilon_n^2 = \frac{\sigma^2}{n} \text{Tr}((A^\top A)^{-1})$ servira de référence pour évaluer le surcoût statistique dû aux variables cachées, analysé en Section 5.

3 Formulation variationnelle et maximum de vraisemblance

3.1 Densité du couple (Y, Z) et vraisemblance marginale

On revient au modèle général (M), où les Z_i sont i.i.d. de densité f_Z par rapport à μ , et les $E_i \sim \mathcal{N}(0, \text{Id}_p)$ sont indépendants des Z_i .

Loi conditionnelle de Y_i sachant Z_i . Conditionnellement à $Z_i = z$, le modèle (M) donne $Y_i = A_z \theta + \sigma E_i$, de sorte que

$$Y_i \mid Z_i = z \sim \mathcal{N}(A_z \theta, \sigma^2 \text{Id}_p).$$

La densité conditionnelle de Y_i sachant $Z_i = z$, par rapport à la mesure de Lebesgue λ_p sur $\mathbb{R}^p$, est donc

$$p(y \mid z; \theta) = \frac{1}{(2\pi\sigma^2)^{p/2}} \exp\left(-\frac{\|y - A_z \theta\|^2}{2\sigma^2}\right). \quad (4)$$

Densité jointe du couple (Y_i, Z_i) . Les variables Y_i et Z_i ne sont pas indépendantes, Z_i détermine la transformation appliquée à θ avant que Y_i soit observé, mais leur loi jointe se factorise selon

$$p(y, z; \theta) = p(y \mid z; \theta) \cdot f_Z(z) = \frac{f_Z(z)}{(2\pi\sigma^2)^{p/2}} \exp\left(-\frac{\|y - A_z \theta\|^2}{2\sigma^2}\right),$$

densité par rapport à $\lambda_p \otimes \mu$ sur $\mathbb{R}^p \times \mathcal{Z}$.

Vraisemblance marginale. L'observateur ne dispose que des Y_i : les Z_i sont cachés. La densité marginale de Y_i s'obtient en intégrant la loi jointe sur $\mathcal{Z}$:

$$p(y; \theta) = \int_{\mathcal{Z}} p(y \mid z; \theta) f_Z(z) d\mu(z) = \frac{1}{(2\pi\sigma^2)^{p/2}} \int_{\mathcal{Z}} f_Z(z) \exp\left(-\frac{\|y - A_z \theta\|^2}{2\sigma^2}\right) d\mu(z). \quad (5)$$

Les observations $Y_1, \dots, Y_n$ étant i.i.d. de densité (5), la log-vraisemblance marginale vaut

$$\ell_n(\theta) = \sum_{i=1}^n \log p(Y_i; \theta) = -\frac{np}{2} \log(2\pi\sigma^2) + \sum_{i=1}^n \log \int_{\mathcal{Z}} f_Z(z) \exp\left(-\frac{\|Y_i - A_z \theta\|^2}{2\sigma^2}\right) d\mu(z). \quad (6)$$

Chaque terme de la somme est le logarithme d'une intégrale d'exponentielles : une structure *log-sum-exp*, qui contraste avec la forme quadratique du cas sans variables

cachées (2).

Application au Cas 1. Dans le Cas 1, $\mathcal{Z} = [0, 2\pi[$, $f_Z \equiv 1$ (loi uniforme normalisée) et $A_z\theta$ est l'évaluation de θ translatée de z sur la grille. La log-vraisemblance (6) devient

$$\ell_n(\theta) = -\frac{np}{2} \log(2\pi\sigma^2) - n \log(2\pi) + \sum_{i=1}^n \log \int_0^{2\pi} \exp\left(-\frac{\|Y_i - A_z\theta\|^2}{2\sigma^2}\right) dz.$$

En pratique, l'intégrale sur $[0, 2\pi[$ est approchée par une quadrature de Riemann sur n_z points équirépartis $z_q = 2\pi q/n_z$:

$$\int_0^{2\pi} \exp\left(-\frac{\|y - A_z\theta\|^2}{2\sigma^2}\right) dz \approx \frac{2\pi}{n_z} \sum_{q=0}^{n_z-1} \exp\left(-\frac{\|y - A_{z_q}\theta\|^2}{2\sigma^2}\right).$$

Le calcul numérique de ce log-sum-exp requiert une attention particulière pour éviter les dépassements en virgule flottante, point traité en Section 4.1.

3.2 Propriétés analytiques de la log-vraisemblance

On étudie ici les propriétés de la log-vraisemblance marginale (6) vue comme fonction de $\theta \in E \simeq \mathbb{R}^d$. Pour alléger les notations, on pose

$$q_i(z, \theta) = \frac{\|Y_i - A_z\theta\|^2}{2\sigma^2},$$

de sorte que $\ell_n(\theta) = \sum_{i=1}^n \log \int_{\mathcal{Z}} f_Z(z) e^{-q_i(z, \theta)} d\mu(z)$ à une constante additive près.

Régularité.

Proposition 3.1. *La log-vraisemblance $\ell_n : \mathbb{R}^d \rightarrow \mathbb{R}$ est de classe C^∞ .*

Démonstration. Notons $I_i(\theta) = \int_{\mathcal{Z}} f_Z(z) e^{-q_i(z, \theta)} d\mu(z)$. Puisque $q_i(z, \theta) \geq 0$, on a $0 < e^{-q_i(z, \theta)} \leq 1$ pour tout z et tout θ , ce qui implique $I_i(\theta) \geq \int_{\mathcal{Z}} f_Z(z) d\mu(z) \cdot e^{-C}$ pour tout compact. En particulier, $I_i(\theta) > 0$ partout, et log est C^∞ sur $\mathbb{R}_{>0}$.

Il suffit donc de montrer que $I_i \in C^\infty(\mathbb{R}^d)$. On dérive formellement sous le signe intégral : la dérivée partielle d'ordre k de l'intégrande est de la forme $P_k(z, \theta) e^{-q_i(z, \theta)}$, où P_k est un polynôme de degré k en les composantes de $Y_i - A_z\theta$ et en celles de $A_z^\top(Y_i - A_z\theta)$. Pour dominer uniformément en z , on utilise la borne classique

$$t^k e^{-t^2/(2\sigma^2)} \leq \left(\frac{k\sigma^2}{e}\right)^{k/2} \quad \forall t \geq 0,$$

avec $t = \|Y_i - A_z \theta\|$, combinée à la borne uniforme en z sur la norme opérateur :

$$\sup_{z \in \mathcal{Z}} \|A_z\|_{\text{op}} < \infty.$$

Dans le Cas 1, cette borne est exactement $\sqrt{p}$, indépendant de z , car $A_z^\top A_z = p \text{Id}_d$ pour toute translation z . Dans le Cas 2, elle découle de la compacité de $SO(2)$ et de la continuité de $z \mapsto A_z$.

On obtient ainsi une fonction dominante intégrable sur $\mathcal{Z}$ (en fait constante), et le théorème de dérivation sous le signe intégral s'applique à tout ordre. $\square$

Remarque 3.2. La même démonstration vaut lorsque $\mathcal{Z}$ est discret et fini, auquel cas l'intégrale devient une somme finie : la somme de fonctions C^∞ est C^∞ .

Gradient et poids a posteriori. La régularité établie ci-dessus garantit l'existence du gradient de ℓ_n . On le calcule en dérivant sous le signe intégral. On introduit pour chaque couple (i, z) les *poids a posteriori*

$$w_{i,z}(\theta) = \frac{f_Z(z) e^{-q_i(z,\theta)}}{\int_{\mathcal{Z}} f_Z(z') e^{-q_i(z',\theta)} d\mu(z')}, \quad (7)$$

qui vérifient $w_{i,z}(\theta) \geq 0$ et $\int_{\mathcal{Z}} w_{i,z}(\theta) d\mu(z) = 1$. Ces poids représentent la probabilité conditionnelle que la variable cachée Z_i vaille z , sachant l'observation Y_i et le paramètre courant θ .

Proposition 3.3. *Le gradient de ℓ_n en θ est donné par*

$$\nabla_{\theta} \ell_n(\theta) = \frac{1}{\sigma^2} \sum_{i=1}^n \int_{\mathcal{Z}} w_{i,z}(\theta) A_z^\top (Y_i - A_z \theta) d\mu(z). \quad (8)$$

Démonstration. On dérive $\log I_i(\theta)$ en appliquant la règle de la chaîne :

$$\nabla_{\theta} \log I_i(\theta) = \frac{\nabla_{\theta} I_i(\theta)}{I_i(\theta)}.$$

Puis, en dérivant sous le signe intégral (justifié par la domination établie plus haut) :

$$\nabla_{\theta} I_i(\theta) = \int_{\mathcal{Z}} f_Z(z) e^{-q_i(z,\theta)} \nabla_{\theta} (-q_i(z,\theta)) d\mu(z) = \frac{1}{\sigma^2} \int_{\mathcal{Z}} f_Z(z) e^{-q_i(z,\theta)} A_z^\top (Y_i - A_z \theta) d\mu(z).$$

En divisant par $I_i(\theta)$, on reconnaît les poids (7), et la formule (8) s'obtient en sommant sur i . $\square$

Remarque 3.4. Le gradient s'annule en θ^* si et seulement si θ^* satisfait l'équation

de cohérence

$$\left(\int_{\mathcal{Z}} \sum_{i=1}^n w_{i,z}(\theta^*) A_z^\top A_z d\mu(z) \right) \theta^* = \int_{\mathcal{Z}} \sum_{i=1}^n w_{i,z}(\theta^*) A_z^\top Y_i d\mu(z).$$

Les poids $w_{i,z}(\theta^*)$ dépendent eux-mêmes de θ^* : c'est précisément cette structure de point fixe que l'algorithme EM exploite (Section 4.2).

Coercivité.

Proposition 3.5. *La log-vraisemblance ℓ_n est coercive : $\ell_n(\theta) \rightarrow -\infty$ lorsque $\|\theta\| \rightarrow +\infty$. En particulier, le problème de maximisation admet au moins un maximum global.*

Démonstration. Pour $\|\theta\| \rightarrow \infty$, comme A_z est injectif (hypothèse $p \geq d$) et $z \mapsto A_z$ est bornée, on a $\|A_z \theta\| \rightarrow \infty$ uniformément en z sur tout compact de $\mathcal{Z}$. Donc $q_i(z, \theta) \rightarrow +\infty$, chaque terme $e^{-q_i(z, \theta)} \rightarrow 0$, et par le lemme de Fatou $I_i(\theta) \rightarrow 0$, d'où $\log I_i(\theta) \rightarrow -\infty$. L'ensemble des maximiseurs est donc non vide et compact. $\square$

Non-concavité. Contrairement au cas sans variables cachées (Section 2), où $-\ell_n$ est une forme quadratique convexe, la log-vraisemblance marginale est en général *non concave*.

Remarque 3.6. La non-concavité provient de la structure log-sum-exp. Un mélange de gaussiennes n'est pas log-concave en général : la densité peut présenter plusieurs modes, et ℓ_n hérite de cette géométrie. Cela implique que la descente de gradient peut converger vers un maximum local qui n'est pas global, et justifie l'usage de multi-départs dans l'implémentation numérique.

Comportements asymptotiques.

Remarque 3.7. Deux régimes extrêmes illustrent la géométrie du problème. Lorsque $\sigma \rightarrow 0$, les exponentielles $e^{-q_i(z, \theta)}$ se concentrent sur le z minimisant $\|Y_i - A_z \theta\|^2$: les poids $w_{i,z}(\theta)$ tendent vers une masse de Dirac en $\hat{z}_i(\theta)$, et le problème se réduit à une estimation par affectation dure des variables cachées. Lorsque $\sigma \rightarrow +\infty$, les poids deviennent uniformes ($w_{i,z} \rightarrow f_Z(z)$), toute information sur les Z_i est perdue, et la log-vraisemblance se comporte comme une constante en θ — le problème est alors non identifiable.

3.3 Identifiabilité et choix d'une métrique adaptée

Définition 3.8 (Identifiabilité). Le modèle (M) est *identifiable* si

$$p(\cdot; \theta) = p(\cdot; \theta') \implies \theta = \theta'.$$

En l'absence d'identifiabilité, plusieurs paramètres produisent les mêmes distributions d'observations : la log-vraisemblance admet plusieurs maximiseurs indiscernables par les données.

Non-identifiabilité dans le Cas 1. Dans le Cas 1, les translations forment un groupe d'invariance de la log-vraisemblance. Pour $a \in [0, 2\pi[$, on note τ_a l'opérateur de translation :

$$(\tau_a \theta)(x) = \theta(x - a), \quad x \in [0, 2\pi[.$$

Proposition 3.9. *Pour tout $\theta \in E$ et tout $a \in [0, 2\pi[$, $\ell_n(\tau_a \theta) = \ell_n(\theta)$.*

Démonstration. L'opérateur A_z évalue la translatée de θ sur la grille : $(A_z \theta)_j = \theta(x_j - z)$. On a donc

$$(A_z(\tau_a \theta))_j = (\tau_a \theta)(x_j - z) = \theta(x_j - z - a) = (A_{z+a} \theta)_j,$$

soit $A_z(\tau_a \theta) = A_{z+a} \theta$. En substituant dans la log-vraisemblance (6) (Cas 1, $f_Z \equiv 1$) :

$$\ell_n(\tau_a \theta) = C + \sum_{i=1}^n \log \int_0^{2\pi} \exp\left(-\frac{\|Y_i - A_{z+a} \theta\|^2}{2\sigma^2}\right) \frac{dz}{2\pi},$$

où $C = -\frac{np}{2} \log(2\pi\sigma^2) - n \log(2\pi)$ ne dépend pas de θ . Le changement de variable $z' = z + a \pmod{2\pi}$ laisse l'intégrale sur $[0, 2\pi[$ invariante (la mesure de Lebesgue est invariante par translation sur le tore), d'où $\ell_n(\tau_a \theta) = \ell_n(\theta)$. $\square$

Inadaptation de la norme standard. La Proposition 3.9 implique que si $\hat{\theta}_n$ maximise ℓ_n , alors $\tau_a \hat{\theta}_n$ le maximise aussi pour tout $a \in [0, 2\pi[$. Les données ne permettent donc d'estimer θ qu'à une translation près. Utiliser $\|\hat{\theta}_n - \theta\|$ comme mesure d'erreur est alors inadapté : même un estimateur parfait « à translation près » peut donner une grande erreur si le décalage résiduel n'est pas corrigé.

Définition 3.10 (Orbite et distance quotient). L'*orbite* de θ sous le groupe des translations est

$$[\theta] = \{\tau_a \theta : a \in [0, 2\pi[\}.$$

La *distance quotient* entre $[\hat{\theta}_n]$ et $[\theta]$ est

$$d([\hat{\theta}_n], [\theta]) = \inf_{a \in [0, 2\pi[} \|\tau_a \hat{\theta}_n - \theta\|.$$

Erreur quadratique invariante. On définit l'erreur quadratique adaptée au problème d'identifiabilité :

$$\varepsilon_n^2(\sigma) = \mathbb{E} \left[\inf_{a \in [0, 2\pi[} \|\tau_a \hat{\theta}_n - \theta\|^2 \right]. \quad (9)$$

Cette quantité est invariante par toute transformation $\theta \mapsto \tau_a \theta$, nulle si et seulement si $\hat{\theta}_n \in [\theta]$ presque sûrement, et bien définie car l'infimum est atteint (l'application $a \mapsto \left\| \tau_a \hat{\theta}_n - \theta \right\|^2$ est continue sur le compact $[0, 2\pi[$). C'est (9) qui sera étudiée numériquement en Section 5.

4 Résolution du problème d'optimisation

Nous cherchons à maximiser $\ell_n(\theta)$ sur $\mathbb{R}^d$. Deux approches sont présentées : la descente de gradient, qui exploite directement la différentiabilité de ℓ_n , et l'algorithme EM, qui tire parti de la structure à données cachées pour ramener chaque itération à un problème quadratique explicite.

4.1 Descente de gradient directe

4.1.1 Rappel du gradient

La Proposition 3.3 (Section 3.2) établit que

$$\nabla_{\theta} \ell_n(\theta) = \frac{1}{\sigma^2} \sum_{i=1}^n \int_{\mathcal{Z}} w_{i,z}(\theta) A_z^{\top} (Y_i - A_z \theta) d\mu(z),$$

où les poids a posteriori $w_{i,z}(\theta)$ sont définis en (7). Le gradient s'interprète comme une espérance pondérée des résidus $Y_i - A_z \theta$ par rapport à la loi a posteriori de Z_i sachant Y_i .

4.1.2 Itération et choix du pas

À partir d'une initialisation $\theta^{(0)} \in \mathbb{R}^d$, l'itération de montée de gradient est

$$\theta^{(k+1)} = \theta^{(k)} + \eta_k \nabla_{\theta} \ell_n(\theta^{(k)}).$$

Règle d'Armijo. Le pas $\eta_k > 0$ est sélectionné par recherche linéaire par retrait (*backtracking*) : en notant $g^{(k)} = \nabla_{\theta} \ell_n(\theta^{(k)})$, on cherche le plus grand élément de la suite $\eta_0, \eta_0/2, \eta_0/4, \dots$ satisfaisant

$$\ell_n(\theta^{(k)} + \eta g^{(k)}) \geq \ell_n(\theta^{(k)}) + c \eta \|g^{(k)}\|^2, \quad (10)$$

avec $c \in (0, 1)$ fixé (typiquement $c = 10^{-4}$). Cette condition garantit un accroissement suffisant de la log-vraisemblance à chaque pas ; son existence est assurée par la différentiabilité de ℓ_n (Proposition en début de Section 3.2).

Multi-départs. La log-vraisemblance n'étant pas concave (Section 3.2), on utilise plusieurs initialisations aléatoires et on retient la solution de plus haute vraisemblance finale.

4.1.3 Application au Cas 1

Dans le Cas 1, $A_z = \Phi(z)$ est la matrice d'évaluation ($p \times d$) dont la colonne 0 vaut **1** et les colonnes $2k-1, 2k$ valent $\cos(k(\cdot - z)), \sin(k(\cdot - z))$ évaluées sur la grille spatiale. Le gradient se spécialise en

$$\nabla_{\theta} \ell_n(\theta) = \frac{1}{\sigma^2} \sum_{i=1}^n \int_0^{2\pi} w_{i,z}(\theta) \Phi(z)^\top (Y_i - \Phi(z)\theta) \frac{dz}{2\pi},$$

l'intégrale sur $[0, 2\pi[$ étant approchée par quadrature de Riemann sur n_z points (même discrétisation qu'en Section 3.1). Le coût par itération de gradient est $O(n \cdot n_z \cdot pd)$.

4.2 Algorithme Espérance-Maximisation (EM)

4.2.1 Log-vraisemblance des données complètes

Si les variables cachées $Z_1, \dots, Z_n$ étaient observées, la log-vraisemblance *complète* serait

$$\ell_n^c(\theta; Z) = -\frac{np}{2} \log(2\pi\sigma^2) - \frac{1}{2\sigma^2} \sum_{i=1}^n \|Y_i - A_{Z_i}\theta\|^2 + \sum_{i=1}^n \log f_Z(Z_i). \quad (11)$$

Elle est *quadratique* en θ : si les Z_i étaient connus, son maximiseur serait accessible par un système linéaire analogue à (2). L'algorithme EM exploite cette structure en remplaçant les Z_i inconnus par leur loi a posteriori.

4.2.2 Fonction auxiliaire Q

À l'itération k , on pose

$$Q(\theta \mid \theta^{(k)}) = \mathbb{E}_{\theta^{(k)}} \left[\ell_n^c(\theta; Z) \mid Y_1, \dots, Y_n \right]. \quad (12)$$

Les termes de (11) indépendants de θ contribuent à une constante additive ; il reste

$$Q(\theta \mid \theta^{(k)}) = -\frac{1}{2\sigma^2} \sum_{i=1}^n \int_{\mathcal{Z}} w_{i,z}(\theta^{(k)}) \|Y_i - A_z\theta\|^2 d\mu(z) + \text{cte}, \quad (13)$$

où les poids $w_{i,z}(\theta^{(k)})$ sont les poids a posteriori (7) évalués au paramètre courant. La fonction $Q(\cdot \mid \theta^{(k)})$ est quadratique concave en θ .

4.2.3 Étape E (Espérance)

Calculer les poids a posteriori $w_{i,z}(\theta^{(k)})$ pour tout i et presque tout $z \in \mathcal{Z}$, par la définition (7) appliquée à $\theta^{(k)}$:

$$w_{i,z}(\theta^{(k)}) = \frac{f_Z(z) \exp\left(-\frac{\|Y_i - A_z \theta^{(k)}\|^2}{2\sigma^2}\right)}{\int_{\mathcal{Z}} f_Z(z') \exp\left(-\frac{\|Y_i - A_{z'} \theta^{(k)}\|^2}{2\sigma^2}\right) d\mu(z')}. \quad (14)$$

4.2.4 Étape M (Maximisation)

On maximise $Q(\theta \mid \theta^{(k)})$ en θ . La fonction (13) étant quadratique, on annule son gradient :

$$\nabla_{\theta} Q(\theta \mid \theta^{(k)}) = \frac{1}{\sigma^2} \sum_{i=1}^n \int_{\mathcal{Z}} w_{i,z}(\theta^{(k)}) A_z^{\top} (Y_i - A_z \theta) d\mu(z) = 0.$$

En développant et en isolant θ , on obtient le système linéaire

$$M^{(k)} \theta^{(k+1)} = b^{(k)}, \quad (15)$$

avec

$$M^{(k)} = \sum_{i=1}^n \int_{\mathcal{Z}} w_{i,z}(\theta^{(k)}) A_z^{\top} A_z d\mu(z) \in \mathbb{R}^{d \times d}, \quad (16)$$

$$b^{(k)} = \sum_{i=1}^n \int_{\mathcal{Z}} w_{i,z}(\theta^{(k)}) A_z^{\top} Y_i d\mu(z) \in \mathbb{R}^d. \quad (17)$$

La matrice $M^{(k)}$ est symétrique définie positive dès que les poids sont non dégénérés et $p \geq d$; le système (15) admet alors une unique solution.

Application au Cas 1. Dans le Cas 1 ($A_z = \Phi(z)$, $f_Z \equiv \frac{1}{2\pi}$), les intégrales sont approchées par quadrature de Riemann sur n_z points :

$$M^{(k)} \approx \frac{1}{n_z} \sum_{i=1}^n \sum_{q=0}^{n_z-1} w_{i,z_q}(\theta^{(k)}) \Phi(z_q)^{\top} \Phi(z_q), \quad b^{(k)} \approx \frac{1}{n_z} \sum_{i=1}^n \sum_{q=0}^{n_z-1} w_{i,z_q}(\theta^{(k)}) \Phi(z_q)^{\top} Y_i.$$

Le système (15) est de taille $d \times d$ (avec $d = 2N + 1 \ll p$); sa résolution en $O(d^3)$ est négligeable devant le coût $O(n \cdot n_z \cdot pd)$ de l'étape E.

4.2.5 Propriétés

Proposition 4.1 (Monotonie, [3]). *L'algorithme EM est monotone : $\ell_n(\theta^{(k+1)}) \geq \ell_n(\theta^{(k)})$ pour tout $k \geq 0$.*

Démonstration. Soit q une densité de probabilité arbitraire sur $\mathcal{Z}$ (par rapport à μ), c'est-à-dire $\int_{\mathcal{Z}} q(z) d\mu(z) = 1$. En multipliant l'intégrande par $q(z)/q(z)$ et en appliquant l'inégalité de Jensen (concavité de $\log$), on a

$$\log p(Y; \theta) = \log \int_{\mathcal{Z}} \frac{p(Y, Z; \theta)}{q(Z)} q(Z) d\mu(Z) \geq \int_{\mathcal{Z}} q(Z) \log \frac{p(Y, Z; \theta)}{q(Z)} d\mu(Z).$$

Choisissons $q(Z) = p(Z | Y; \theta^{(k)})$. L'inégalité devient

$$\log p(Y; \theta) \geq \int p(Z | Y; \theta^{(k)}) \log p(Y, Z; \theta) d\mu(Z) - \int p(Z | Y; \theta^{(k)}) \log p(Z | Y; \theta^{(k)}) d\mu(Z).$$

Le second terme, noté $C(\theta^{(k)})$, ne dépend pas de θ . Ainsi,

$$\ell_n(\theta) \geq Q(\theta | \theta^{(k)}) + C(\theta^{(k)}).$$

L'égalité a lieu pour $\theta = \theta^{(k)}$, car alors

$$\frac{p(Y, Z; \theta^{(k)})}{p(Z | Y; \theta^{(k)})} = p(Y; \theta^{(k)})$$

ne dépend pas de Z , condition qui rend l'inégalité de Jensen une égalité.

Appliquons ce résultat à $\theta = \theta^{(k+1)}$ et $\theta = \theta^{(k)}$:

$$\ell_n(\theta^{(k+1)}) \geq Q(\theta^{(k+1)} | \theta^{(k)}) + C(\theta^{(k)}), \quad \ell_n(\theta^{(k)}) = Q(\theta^{(k)} | \theta^{(k)}) + C(\theta^{(k)}).$$

Par définition de l'étape M, $Q(\theta^{(k+1)} | \theta^{(k)}) \geq Q(\theta^{(k)} | \theta^{(k)})$. En soustrayant, on obtient

$$\ell_n(\theta^{(k+1)}) - \ell_n(\theta^{(k)}) \geq Q(\theta^{(k+1)} | \theta^{(k)}) - Q(\theta^{(k)} | \theta^{(k)}) \geq 0.$$

□

Remarque 4.2. La monotonie vaut même si l'étape M est remplacée par une étape augmentant Q sans le maximiser exactement (algorithme GEM, *Generalized EM*).

Théorème 4.3 ([7]). *Sous des conditions de régularité sur ℓ_n (continuité de $\theta \mapsto Q(\theta | \theta')$ et compacité des sous-niveaux), toute valeur d'adhérence de la suite $(\theta^{(k)})$ est un point stationnaire de ℓ_n , c'est-à-dire vérifie $\nabla_{\theta} \ell_n(\theta) = 0$.*

Remarque 4.4. La preuve combine la monotonie (Proposition 4.1) et la coercivité de ℓ_n (Section 3.2), qui confinent la suite dans un compact et garantissent la convergence

de $(\ell_n(\theta^{(k)}))$; la continuité de $\theta \mapsto Q(\theta \mid \theta')$ permet alors de montrer que toute valeur d'adhérence θ^* est un point fixe de l'itération, condition équivalente à $\nabla_{\theta} \ell_n(\theta^*) = 0$ d'après la décomposition $\ell_n(\theta) = Q(\theta \mid \theta^*) - R(\theta \mid \theta^*)$ différenciée en θ^* .

4.3 Comparaison des deux approches

La **descente de gradient** est directe et polyvalente : la règle d'Armijo (10) garantit un accroissement de ℓ_n à chaque itération, mais l'algorithme est sensible au choix du pas initial η_0 et peut converger lentement vers un maximum local.

L'**algorithme EM** est particulièrement adapté aux modèles à variables cachées : la monotonie est garantie par la Proposition 4.1, et l'étape M se réduit à un système linéaire de taille $d \times d$, dont le coût $O(d^3)$ est négligeable devant l'étape E. La convergence est linéaire près d'un optimum, mais l'algorithme est numériquement robuste et ses valeurs d'adhérence sont toutes des points stationnaires (Théorème 4.3).

Les deux algorithmes partagent la même structure : une étape de calcul des poids (7) de coût $O(n \cdot n_z \cdot pd)$, suivie d'une mise à jour de θ . L'étude numérique de leurs performances sur le Cas 1 est conduite en Section 5.

5 Analyse de la qualité de l'estimation

5.1 Retour au cas général avec variables cachées

Contraste avec le cas de référence. Dans la Section 2, le modèle simplifié $Y_i = A\theta + \sigma E_i$ (sans variables cachées) admettait un estimateur explicite (3),

$$\hat{\theta}_n = (A^\top A)^{-1} A^\top \bar{Y}_n,$$

et l'erreur quadratique se calculait exactement (Section 2.3) :

$$\varepsilon_n^2(\sigma) = \frac{\sigma^2}{n} \text{Tr}((A^\top A)^{-1}).$$

Dans le modèle général (M) avec variables cachées, la log-vraisemblance marginale ℓ_n n'est plus quadratique (Section 3), et $\hat{\theta}_n$ est désormais la sortie d'un algorithme itératif — EM ou descente de gradient (Section 4) — dont on ne peut pas écrire la forme close. Il n'existe donc pas d'analogue direct de la formule ci-dessus : l'erreur doit être étudiée numériquement.

Inadaptation de la norme euclidienne dans le Cas 1. Un second obstacle s'ajoute dans le Cas 1. La Proposition 3.9 (Section 3.3) établit que ℓ_n est invariante par translation : si $\hat{\theta}_n$ est un maximiseur de ℓ_n , alors $\tau_a \hat{\theta}_n$ l'est aussi pour tout $a \in [0, 2\pi[$. Le paramètre n'est donc identifiable qu'à une translation près, et la norme euclidienne $\|\hat{\theta}_n - \theta\|$ n'est pas une mesure d'erreur adaptée : même un estimateur parfait à translation près peut produire un grand résidu si le décalage résiduel n'est pas corrigé.

Mesure d'erreur adaptée et approximation empirique. On utilise la quantité invariante par translation définie en (9) :

$$\varepsilon_n(\sigma) = \left(\mathbb{E} \left[\inf_{a \in [0, 2\pi[} \left\| \tau_a \hat{\theta}_n - \theta \right\|^2 \right] \right)^{1/2}.$$

Deux approximations rendent ce calcul numérique accessible.

Infimum sur a . Pour un estimateur $\hat{\theta}_n$ donné, le décalage optimal $a^* = \arg \min_a \left\| \tau_a \hat{\theta}_n - \theta \right\|^2$ est approché par corrélation croisée via FFT : a^* est la position du maximum de $a \mapsto \langle \tau_a \hat{\theta}_n, \theta \rangle$, calculé en $O(p \log p)$ par transformée de Fourier rapide (fonction `translation_error` dans le notebook).

Espérance sur les données. L'espérance porte sur les n observations $(Y_1, \dots, Y_n)$ et les n translations cachées $(Z_1, \dots, Z_n)$ qui les ont générées. Elle est approchée par une moyenne de Monte-Carlo sur M répétitions indépendantes de l'expérience : pour

chaque répétition m , on tire des translations et des bruits indépendants, on calcule l'estimateur $\hat{\theta}_n^{(m)}$ par l'algorithme retenu, puis on mesure l'erreur invariante par translation. La moyenne empirique

$$\hat{\varepsilon}_n(\sigma) = \left(\frac{1}{M} \sum_{m=1}^M \inf_{a \in [0, 2\pi[} \left\| \tau_a \hat{\theta}_n^{(m)} - \theta \right\|^2 \right)^{1/2} \quad (18)$$

est l'estimateur de $\varepsilon_n(\sigma)$ tracé en Section 5.2.

5.2 Étude numérique de $\varepsilon_n(\sigma)$

Protocole. Les expériences sont conduites dans le Cas 1 avec les paramètres suivants : $p = 32$ points de grille, $N = 3$ fréquences ($d = 7$), $n_z = 64$ points de quadrature pour l'intégrale sur z , et $M = 15$ répétitions Monte-Carlo par point de mesure. L'algorithme EM est lancé avec 20 initialisations aléatoires (amplitude 0,5) par répétition ; on retient la solution de meilleure log-vraisemblance finale. L'erreur estimée $\hat{\varepsilon}_n(\sigma)$ est calculée via (18). La courbe de référence tracée en tirets est celle de la Section 2 :

$$\varepsilon_n^{\text{ref}}(\sigma) = \frac{\sigma}{\sqrt{n}} \sqrt{\text{Tr}[(A^T A)^{-1}]}, \quad \text{Tr}[(\Phi(0)^T \Phi(0))^{-1}] \approx 0,41,$$

qui correspond au cas où les translations Z_i sont connues (oracle).




FIGURE 2 – Erreur $\hat{\varepsilon}_n(\sigma)$ en fonction du nombre d'observations n (échelles log-log) pour quatre valeurs de σ . Trait plein : EM multi-départ. Tirets de même couleur : référence oracle de la Section 2.3.

Plateau algorithmique et goulot d'étranglement. La figure 2 révèle le phénomène central de cette étude. Pour $\sigma \in \{0,3, 0,5, 1,0\}$, l'erreur EM se stabilise autour de 0,10–0,13 dès $n \approx 50$ et ne décroît plus lorsque n augmente, alors que la courbe de référence oracle continue de suivre la pente $n^{-1/2}$. Ce décalage croissant d'un facteur 1,5 à $n = 10$ jusqu'à 4,5 à $n = 200$, ne provient pas d'une insuffisance statistique du modèle : plus de données n'améliore pas l'estimation parce que l'algorithme EM converge vers un optimum local de la log-vraisemblance marginale, elle-même non concave. Le goulot d'étranglement est donc *algorithmique* plutôt que statistique.

Anomalie à faible bruit ($\sigma = 0,1$). Dès $\sigma = 0,1$, l'erreur EM est nettement plus élevée ($\widehat{\varepsilon}_n \approx 0,27\text{--}0,37$) et ne suit plus la décroissance attendue. L'explication réside dans la structure des poids a posteriori (14) : à faible σ , le terme $\exp(-\|Y_i - \Phi(z)u\|^2/2\sigma^2)$ est extrêmement piqué, si bien que les poids $w_{i,z}(u^{(k)})$ se concentrent quasi intégralement sur un seul point de quadrature pour chaque i . L'entropie de Shannon de la distribution a posteriori, $H_i = -\sum_q w_{i,z_q} \log w_{i,z_q}$, vaut alors $H \approx 0,007$ (valeur maximale possible : $\log n_z \approx 4,16$). L'E-step voit essentiellement un unique candidat pour chaque translation, et le M-step qui en résulte devient très sensible aux optima locaux : l'EM reste piégé dans un attracteur qui n'est pas le maximum global. Pour $\sigma = 0,05$ le phénomène est encore plus sévère et l'estimation échoue complètement ($\widehat{\varepsilon}_n \approx 0,97$).

Exception aux grands σ et petits n . Pour $n = 10$ et $\sigma = 1,0$, l'erreur EM ($\approx 0,17$) est *inférieure* à la référence oracle ($\approx 0,20$). Cela n'est pas paradoxal : la borne de référence est construite pour $A_z = A$ constant (translations connues), et surestime donc le risque réel lorsque le nombre d'observations est si petit que l'estimation pâtit davantage de la variance que du biais lié aux translations cachées.




FIGURE 3 – Erreur $\hat{\varepsilon}_n(\sigma)$ en fonction du niveau de bruit σ pour quatre valeurs de n fixées. On observe une courbe en forme de U : l’erreur est élevée aux deux extrêmes et minimale pour $\sigma \in [0,2,0,5]$.

Comportement en fonction de σ : courbe en U. La figure 3 révèle trois régimes distincts selon σ .

- *Faible bruit* ($\sigma \lesssim 0,1$) — *poids concentrés*. Les poids a posteriori sont quasi-Diracs ; l’EM est piégé dans des optima locaux et l’erreur est élevée. L’entropie $H \approx 0,007$ confirme que l’algorithme n’explore pas l’espace des translations.
- *Bruit modéré* ($\sigma \in [0,2,0,5]$) — *régime optimal*. L’erreur atteint son minimum. Les poids sont suffisamment diffus pour que le landscape de la log-vraisemblance présente un bassin d’attraction large autour du vrai paramètre (entropie $H \approx 0,57$ pour $\sigma = 0,5$), tout en restant assez informatifs pour guider l’optimisation.
- *Grand bruit* ($\sigma \gtrsim 1,0$) — *poids uniformes*. Les poids tendent vers l’uniforme ($H \approx 1,28$ pour $\sigma = 1,0$; $H \approx 2,18$ pour $\sigma = 2,0$) : les observations ne permettent plus de discriminer les translations. L’erreur remonte avec σ , et c’est dans ce régime que n commence à nouveau à jouer un rôle visible : les courbes pour $n \in \{50, 100, 200\}$ se séparent nettement, suggérant un retour partiel vers la décroissance $n^{-1/2}$.

6 Régularisation pour les problèmes inverses mal posés

Dans le modèle étudié, l'estimation de θ repose sur l'inversion de matrices de la forme

$$M^{(k)} = \sum_{i=1}^n \int_{\mathcal{Z}} w_{i,z}(\theta^{(k)}) A_z^\top A_z d\mu(z),$$

apparaissant dans l'étape M de l'algorithme EM (cf. (16)).

Dans le Cas 1 (translations sur le tore), les opérateurs A_z conservent globalement l'information du signal, et la diagonalisation de Fourier permet une inversion relativement stable.

En revanche, dans le Cas 2, les opérateurs

$$A_z = P \circ R_z$$

sont des compositions de rotations et de projections. L'opérateur de projection

$$P : L^2(B(0, 1)) \rightarrow L^2([-1, 1])$$

réduit la dimension des données observées et entraîne une perte d'information intrinsèque.

Certaines composantes de θ influencent alors très faiblement les observations, ce qui rend le problème inverse mal posé. En particulier, la matrice $M^{(k)}$ possède souvent de très petites valeurs propres, et son inversion amplifie fortement le bruit présent dans les données. Cette instabilité peut provoquer une forte sensibilité au bruit, des oscillations numériques, voire une mauvaise convergence de l'algorithme EM. Pour stabiliser le problème, on introduit une régularisation.

6.1 Vraisemblance pénalisée

On remplace la log-vraisemblance marginale par une version pénalisée :

$$\ell_n^{\text{reg}}(\theta) = \ell_n(\theta) - \lambda R(\theta),$$

où $\lambda > 0$ est un paramètre de régularisation et $R(\theta)$ est un terme de pénalité favorisant des solutions plus régulières.

Dans le cadre de l'algorithme EM, la M-step devient

$$\theta^{(k+1)} = \arg \max_{\theta \in E} Q(\theta \mid \theta^{(k)}) - \lambda R(\theta).$$

Pour la descente de gradient pénalisée, la modification est immédiate : par linéarité de la différentiation,

$$\nabla_{\theta} \ell_n^{\text{reg}}(\theta) = \nabla_{\theta} \ell_n(\theta) - \lambda \theta, \quad (19)$$

et l'itération d'Armijo (cf. Section 4.1) s'applique telle quelle au gradient modifié (19).

6.2 Régularisation de Tikhonov

Le choix le plus simple consiste à prendre $R(\theta) = \frac{1}{2} \|\theta\|^2$. Cette pénalité quadratique correspond à la régularisation de Tikhonov (ou ridge).

La M-step régularisée revient à minimiser

$$\frac{1}{2\sigma^2} \sum_{i=1}^n \int_{\mathcal{Z}} w_{i,z}(\theta^{(k)}) \|Y_i - A_z \theta\|^2 d\mu(z) + \frac{\lambda}{2} \|\theta\|^2.$$

En annulant le gradient, on obtient les équations normales régularisées :

$$\left(\sum_{i=1}^n \int_{\mathcal{Z}} w_{i,z}(\theta^{(k)}) A_z^{\top} A_z d\mu(z) + \lambda \sigma^2 I \right) \theta = \sum_{i=1}^n \int_{\mathcal{Z}} w_{i,z}(\theta^{(k)}) A_z^{\top} Y_i d\mu(z).$$

La mise à jour EM régularisée est donc

$$\theta^{(k+1)} = \left(\sum_{i=1}^n \int_{\mathcal{Z}} w_{i,z}(\theta^{(k)}) A_z^{\top} A_z d\mu(z) + \lambda \sigma^2 I \right)^{-1} \left(\sum_{i=1}^n \int_{\mathcal{Z}} w_{i,z}(\theta^{(k)}) A_z^{\top} Y_i d\mu(z) \right). \quad (20)$$

L'ajout du terme $\lambda \sigma^2 I$ améliore le conditionnement de la matrice à inverser et réduit l'amplification du bruit.

Remarque 6.1 (Interprétation bayésienne). La pénalité $\frac{\lambda}{2} \|\theta\|^2$ est le log-prior d'une loi gaussienne sphérique $\theta \sim \mathcal{N}\left(0, \frac{\sigma^2}{\lambda} \text{Id}\right)$. Maximiser $\ell_n^{\text{reg}}(\theta)$ revient donc à calculer l'estimateur MAP (*maximum a posteriori*) associé à ce prior : la régularisation de Tikhonov est la traduction fréquentiste d'une information a priori sur l'amplitude de θ .

6.3 Pénalités non quadratiques : ℓ^1 et variation totale

La pénalité de Tikhonov est optimale lorsque θ est supposé de faible amplitude sans structure particulière. D'autres choix de R répondent à des contraintes différentes sur la solution.

Pénalité ℓ^1 (Lasso). On prend

$$R(\theta) = \|\theta\|_1 = \sum_{j=1}^d |\theta_j|.$$

Contrairement à la pénalité quadratique, la norme ℓ^1 est non différentiable en zéro et induit de la *parcimonie* : pour λ assez grand, certaines composantes de $\hat{\theta}(\lambda)$ sont exactement nulles. Elle est donc appropriée lorsque le signal θ est supposé creux dans la base choisie.

La M-step régularisée ℓ^1 n'admet plus de forme close, car le problème

$$\arg \min_{\theta \in E} \frac{1}{2\sigma^2} \sum_{i=1}^n \int_{\mathcal{Z}} w_{i,z}(\theta^{(k)}) \|Y_i - A_z \theta\|^2 d\mu(z) + \lambda \|\theta\|_1$$

est un problème d'optimisation convexe non lisse. On le résout par *descente proximale* : l'opérateur proximal de $\lambda \|\cdot\|_1$ est le seuillage doux composante par composante,

$$\text{prox}_{\lambda \|\cdot\|_1}(\theta)_j = \text{sign}(\theta_j) \max(|\theta_j| - \lambda, 0),$$

ce qui conduit à un algorithme ISTA/FISTA pour la M-step.

Variation totale. Lorsque θ représente un signal échantillonné sur une grille de p points, on peut pénaliser les variations entre points consécutifs :

$$R(\theta) = \text{TV}(\theta) = \sum_{j=1}^{p-1} |\theta_{j+1} - \theta_j|.$$

La variation totale préserve les discontinuités du signal (bords nets) tout en lissant les zones homogènes, ce qui la rend pertinente pour la reconstruction d'images en Cas 2. Comme ℓ^1 , elle est non lisse et nécessite un algorithme proximal (ou dual).

Résumé comparatif.

- *Tikhonov* (ℓ^2) : forme close pour le M-step, stable numériquement, favorise les solutions de petite norme mais denses.
- *Lasso* (ℓ^1) : favorise la parcimonie, M-step résolue par seuillage doux (ISTA/FISTA), adapté quand θ est creux dans la base.
- *Variation totale* : préserve les discontinuités, pertinente pour les images ou signaux par morceaux, M-step résolue par algorithme proximal ou dual.

6.4 Interprétation spectrale

Soient $\mu_1 \geq \mu_2 \geq \dots \geq \mu_d > 0$ les valeurs propres de

$$M^{(k)} = \sum_{i=1}^n \int_{\mathcal{Z}} w_{i,z}(\theta^{(k)}) A_z^\top A_z d\mu(z).$$

Lorsque certaines valeurs propres sont très petites, les directions correspondantes de l'espace des paramètres sont très peu observées par les données : l'inversion de $M^{(k)}$ amplifie fortement le bruit dans ces directions.

La régularisation remplace chaque μ_j par $\mu_j + \lambda\sigma^2$, ce qui évite les divisions par de très petites quantités et stabilise l'inversion. Cette substitution réduit la variance de l'estimateur au prix d'un biais supplémentaire : c'est le compromis classique biais-variance des problèmes inverses statistiques.

6.5 Choix du paramètre λ

Le choix de λ est crucial : une valeur trop petite ne régularise pas suffisamment, une valeur trop grande introduit un biais excessif. Les approches standard pour le calibrer sont les suivantes.

- *Validation croisée (k -fold)*. On partage les n observations en k plis, on estime $\theta(\lambda)$ sur $k - 1$ plis pour plusieurs valeurs de λ , et on retient le λ minimisant l'erreur de prédiction sur le pli laissé de côté.
- *Courbe en L*. On trace $(\log \|Y - A\hat{\theta}(\lambda)\|, \log \|\hat{\theta}(\lambda)\|)$ en faisant varier λ ; la courbe présente typiquement un coude en forme de L dont le sommet indique un bon compromis biais-variance.
- *Validation croisée généralisée (GCV)*. Critère analytique ne nécessitant pas de partition des données, particulièrement adapté aux modèles linéaires régularisés où la matrice chapeau est explicite.

En pratique, la validation croisée est la méthode la plus robuste dans notre cadre, où le modèle à variables cachées complique l'évaluation de la vraisemblance pénalisée pour chaque valeur candidate de λ .

6.6 Résultats numériques

On valide numériquement l'algorithme EM régularisé en Cas 1 sur les mêmes paramètres que la Section 5 : $n = 50$ observations, $p = 32$ points de grille, $N = 3$ fréquences ($d = 7$), $\sigma = 0,3$, $n_z = 50$ points de quadrature.

Monotonie de l'EM régularisé. Pour $\lambda = 0,1$, l'algorithme converge en 21 itérations. Le gain minimal de log-vraisemblance entre deux itérations consécutives vaut

$+4,2 \times 10^{-9} > 0$, ce qui confirme numériquement la monotonie de l'EM (Proposition 4.1) après l'ajout du terme de régularisation.

Effet de λ sur l'erreur d'estimation. La Figure 4 trace l'erreur relative invariante par translation $\hat{\varepsilon}_n(\sigma)$ en fonction de λ sur une grille log-uniforme de 20 valeurs dans $[10^{-3}, 10]$, estimée par $M = 20$ répétitions Monte-Carlo indépendantes avec 3 initialisations aléatoires par répétition.




FIGURE 4 – Erreur relative $\hat{\varepsilon}_n(\sigma)$ en fonction de λ pour l'EM de Tikhonov ($n = 50$, $\sigma = 0,3$, $M = 20$ répétitions). La ligne pointillée rouge indique l'erreur de l'EM non régularisé ($\lambda = 0$).

La courbe présente une forte variabilité Monte-Carlo (oscillations visibles), cohérente avec le faible nombre de répétitions ($M = 20$) et le fait que, dans le Cas 1, $M^{(k)} \approx p \text{Id}_d$ quelle que soit la translation : la matrice à inverser est déjà bien conditionnée, si bien que la régularisation agit principalement sur la variance algorithmique (choix du bassin d'attraction de l'EM) plutôt que sur la variance statistique.

Malgré cette variabilité, deux tendances se dégagent. D'une part, la quasi-totalité des points est *en dessous* de la référence non régularisée ($\hat{\varepsilon} \approx 0,107$, ligne pointillée rouge), confirmant que la régularisation apporte un gain systématique même dans ce cas bien conditionné. D'autre part, un minimum est atteint autour de $\lambda^* \approx 2$ (ligne pointillée verticale), où l'erreur descend à $\approx 0,071$, soit un gain de l'ordre de 33% par rapport à l'EM non régularisé. Pour $\lambda > \lambda^*$, l'erreur remonte progressivement vers la référence : le biais introduit par la contrainte de norme commence à dominer, conformément au compromis biais-variance classique des problèmes inverses régularisés [1]. À très faible λ ($\approx 10^{-2}$), un pic au-dessus de la référence ($\approx 0,13$) illustre le phénomène inverse : une régularisation trop faible ne stabilise pas suffisamment l'optimisation multi-départ et laisse l'EM converger vers des optima locaux de mauvaise qualité.

7 Extensions

7.1 Cas 2 : rotations et projections en 2D

Le Cas 2, introduit en Section 1.2.2, est l'analogie bidimensionnel du problème de cryo-EM. Chaque observation est un sinogramme bruité de θ selon un angle de vue Z_i inconnu :

$$Y_i = A_{Z_i} \theta + \sigma E_i \in \mathbb{R}^p, \quad A_z = \text{ev}_{\text{grille}} \circ P \circ R_z,$$

où R_z est la rotation d'angle z dans $\mathbb{R}^2$ et P est la projection selon l'axe vertical (transformée de Radon, Section 1.2.2). Les algorithmes de la Section 4 s'adaptent formellement, mais cette généralisation fait apparaître des difficultés nouvelles de nature analytique, numérique et liée à l'identifiabilité.

Adaptation de la descente de gradient. La formule du gradient (8) s'applique telle quelle :

$$\nabla_{\theta} \ell_n(\theta) = \frac{1}{\sigma^2} \sum_{i=1}^n \int_{\mathcal{Z}} w_{i,z}(\theta) A_z^{\top} (Y_i - A_z \theta) d\mu(z).$$

Dans le Cas 1, $A_z^{\top} = \Phi(z)^{\top}$ était simplement la transposée d'une matrice d'évaluation, calculée sans surcoût. Dans le Cas 2, l'adjoint $A_z^{\top}$ de l'opérateur de projection est la *rétroprojection* :

$$A_z^{\top} : \mathbb{R}^p \rightarrow E, \quad (A_z^{\top} v)(\mathbf{x}) = \sum_{j=1}^p v_j \delta(x_j - [R_z \mathbf{x}]_1),$$

l'opérateur qui étale chaque valeur v_j le long de la droite verticale correspondante après rotation par R_z . Il s'agit d'un opérateur intégral (transformée de Radon adjointe, ou *backprojection* non filtrée), coûteux à évaluer numériquement : son application en dimension finie requiert une sommation sur l'ensemble de la grille 2D, à comparer au simple produit matriciel $\Phi(z)^{\top} v$ du Cas 1.

Adaptation du M-step EM. La structure du M-step reste identique (15) :

$$M^{(k)} \theta^{(k+1)} = b^{(k)}, \quad M^{(k)} = \sum_{i=1}^n \int_{\mathcal{Z}} w_{i,z}(\theta^{(k)}) A_z^{\top} A_z d\mu(z).$$

Dans le Cas 1, la matrice $\Phi(z)^{\top} \Phi(z)$ est proportionnelle à l'identité quelle que soit la translation z : les colonnes de $\Phi(z)$ sont les exponentielles de Fourier évaluées sur une grille uniforme de p points, et l'orthogonalité discrète donne $\Phi(z)^{\top} \Phi(z) = p \text{Id}_d$. La matrice $M^{(k)}$ est donc un multiple de l'identité, naturellement bien conditionnée, et le M-step se réduit à un simple quotient.

Dans le Cas 2, en revanche, $A_z^\top A_z = R_z^\top P^\top P R_z$, et l'opérateur $P^\top P$ est la convolution par un noyau dont la transformée de Fourier 1D décroît comme $|\xi|^{-1}$: il atténue fortement les hautes fréquences de θ et son inversion amplifie le bruit à toutes les fréquences au-delà du contenu utile du signal. La matrice $M^{(k)}$ hérite de ce mauvais conditionnement — ses plus petites valeurs propres tendent vers zéro avec la résolution du maillage — et l'inversion directe est instable. C'est précisément pourquoi la régularisation de la Section 6 est *indispensable* dans le Cas 2, alors qu'elle reste optionnelle dans le Cas 1 : l'ajout de $\lambda\sigma^2 I$ (cf. (20)) restaure le conditionnement de la matrice à inverser.

Identifiabilité et métrique d'erreur adaptée. La non-identifiabilité du modèle (M) ne disparaît pas dans le Cas 2 : le groupe d'invariance est maintenant $SO(2)$ agissant par rotation sur $L^2(B(0, 1))$.

Proposition 7.1. *Pour tout $\theta \in E$ et tout $a \in [0, 2\pi[$, $\ell_n(R_a\theta) = \ell_n(\theta)$, où $(R_a\theta)(\mathbf{x}) = \theta(R_{-a}\mathbf{x})$.*

Démonstration. Le calcul est analogue à la Proposition 3.9. On vérifie que $A_z(R_a\theta) = A_{z+a}\theta$:

$$(A_z(R_a\theta))_j = (P(R_z(R_a\theta)))(x_j) = (P(R_{z+a}\theta))(x_j) = (A_{z+a}\theta)_j,$$

en utilisant $R_z \circ R_a = R_{z+a}$. La log-vraisemblance ne dépend alors de θ qu'à travers les termes $A_z\theta$, et le changement de variable $z' = z + a \pmod{2\pi}$ laisse l'intégrale sur $[0, 2\pi[$ invariante par invariance de la mesure de Lebesgue sur le groupe. $\square$

Conséquence : si $\hat{\theta}$ est un maximum de ℓ_n , alors $R_a\hat{\theta}$ en est un autre pour tout $a \in [0, 2\pi[$. L'estimateur n'est identifiable qu'à une rotation globale près. Par analogie avec ce qui a été fait dans la Section 3.3 pour le Cas 1, la métrique d'erreur naturelle est

$$\varepsilon = \inf_{a \in [0, 2\pi[} \frac{\|R_a\hat{\theta} - \theta\|}{\|\theta\|},$$

où l'infimum est approché numériquement par corrélation croisée 2D entre les images $\hat{\theta}$ et θ sur la grille, via transformée de Fourier rapide 2D.

Théorème de la tranche de Fourier. Le résultat théorique central du Cas 2 est le *théorème de la tranche de Fourier* (*Fourier slice theorem*), qui relie la transformée de Fourier 2D de θ à l'ensemble de ses projections de Radon [5]. Tout élément $\theta \in E \subset L^2(B(0, 1))$, prolongé par zéro hors de $B(0, 1)$, est bien dans $L^1(\mathbb{R}^2) \cap L^2(\mathbb{R}^2)$ car il est de carré intégrable à support compact.

Théorème 7.2 (Tranche de Fourier). Soit $\theta \in L^1(\mathbb{R}^2) \cap L^2(\mathbb{R}^2)$ et $z \in [0, \pi[$. On note

$$\hat{\theta}(\xi_1, \xi_2) = \int_{\mathbb{R}^2} \theta(\mathbf{x}) e^{-i(\xi_1 x_1 + \xi_2 x_2)} d\mathbf{x}$$

la transformée de Fourier bidimensionnelle de θ . Alors la transformée de Fourier 1D de la projection $P(R_z \theta)$ vérifie :

$$\widehat{P(R_z \theta)}(\xi) = \hat{\theta}(\xi \cos z, -\xi \sin z), \quad \xi \in \mathbb{R}.$$

Esquisse de preuve. Par le théorème de Fubini, on échange les intégrations :

$$\widehat{P(R_z \theta)}(\xi) = \int_{\mathbb{R}^2} (R_z \theta)(x, y) e^{-i\xi x} dx dy.$$

Le changement de variables $(u, v)^\top = R_{-z}(x, y)^\top$ (rotation directe de jacobien 1) donne $(R_z \theta)(x, y) = \theta(u, v)$ et $x = \cos z \cdot u - \sin z \cdot v$, d'où :

$$\widehat{P(R_z \theta)}(\xi) = \int_{\mathbb{R}^2} \theta(u, v) e^{-i(\xi \cos z \cdot u - \xi \sin z \cdot v)} du dv = \hat{\theta}(\xi \cos z, -\xi \sin z). \quad \square$$

Remarque 7.3. Lorsque ξ parcourt $\mathbb{R}$, le point $(\xi \cos z, -\xi \sin z)$ décrit la droite de direction $(\cos z, -\sin z)$ passant par l'origine dans le plan fréquentiel. En faisant varier $z \in [0, \pi[$, on obtient toutes les droites passant par l'origine de $\mathbb{R}^2$: la collection $(P(R_z \theta))_{z \in [0, \pi[}$ détermine donc $\hat{\theta}$ sur $\mathbb{R}^2 \setminus \{0\}$, et θ s'en déduit par transformée de Fourier inverse. Ceci justifie l'identifiabilité du problème *lorsque les Z_i sont connus* : K projections à angles distincts fournissent $\hat{\theta}$ sur K droites fréquentielles, ce qui suffit à reconstruire θ dès que ces droites couvrent les fréquences utiles du signal.

Ce théorème éclaire aussi directement le mauvais conditionnement de $M^{(k)}$: la transformée de Fourier du noyau de $P^\top P$ décroît en $|\xi|^{-1}$ (convolution de Riesz), si bien que l'inversion de $A_z^\top A_z = R_z^\top P^\top P R_z$ amplifie le bruit aux hautes fréquences. C'est cette décroissance qui rend la régularisation de la Section 6 *indispensable* dans le Cas 2 et seulement optionnelle dans le Cas 1.

Bilan comparatif Cas 1 / Cas 2. Le tableau 1 résume les différences structurelles entre les deux cas.

	Cas 1 (translations 1D)	Cas 2 (rotations + projection 2D)
Structure de $A_z^\top A_z$	$p \text{Id}_d$ (indépendant de z , optimal)	$R_z^\top P^\top P R_z$ (spectre $\sim \xi ^{-1}$, mal conditionné)
Cond. de $M^{(k)}$	1 (M-step trivial)	$\rightarrow \infty$ avec la résolution
Régularisation	optionnelle	indispensable
Coût d'un M-step	$O(n_z d^2 + d^3)$	$O(n_z p_{2D} d + d^3)$, coûteux
Groupe d'invariance de ℓ_n	$\mathbb{R}/2\pi\mathbb{Z}$ (translations)	$O(2)$ (rotations + chiralité)
Métrique d'erreur	$\inf_a \ \tau_a \hat{\theta} - \theta\ / \ \theta\ $	$\inf_a \ R_a \hat{\theta} - \theta\ / \ \theta\ $

TABLE 1 – Comparaison structurelle des deux cas du modèle (M).

Ambiguïté chirale. En Cas 2, une subtilité absente du Cas 1 mérite d'être signalée. Notons $\theta^*(\mathbf{x}) = \theta(S\mathbf{x})$ l'image miroir de θ , où $S = \text{diag}(1, -1)$ est la réflexion par rapport à l'axe des abscisses. Un calcul direct utilisant $SR_{-z} = R_z S$ montre que $(P(R_z \theta^*))(x) = (P(R_{-z} \theta))(x)$ pour tout $x \in [-1, 1]$: les projections de θ^* coïncident avec celles de θ vu sous l'angle opposé. Comme les Z_i sont uniformes sur $[0, 2\pi[$, la loi de $-Z_i$ est identique à celle de Z_i , si bien que θ et θ^* produisent des observations de même loi : $\ell_n(\theta^*) = \ell_n(\theta)$ presque sûrement. Le groupe d'ambiguïté est donc $O(2)$ (et non $SO(2)$), contenant en plus une réflexion. Ce *problème de chiralité* [4] est inhérent à la cryo-EM : deux structures biologiques images miroir l'une de l'autre sont indiscernables à partir de leurs seules projections, sans information a priori sur la symétrie moléculaire.

Perspectives. Les difficultés spécifiques du Cas 2 — mauvais conditionnement de $M^{(k)}$, groupe d'ambiguïté $O(2)$, coût numérique élevé — se retrouvent amplifiées dans l'analogue tridimensionnel qui constitue le vrai problème de cryo-EM : chaque observation est alors une image 2D d'une densité volumique $\theta \in L^2(B(0, 1) \subset \mathbb{R}^3)$, et les angles de vue Z_i appartiennent au groupe $SO(3)$ [4, 6]. Une direction d'extension importante consiste à supposer la loi de Z inconnue : l'inférence simultanée de θ et de la distribution des angles constitue alors un problème de mélange non paramétrique dont l'identifiabilité et la vitesse de convergence minimax sont des questions ouvertes [6]. Enfin, les simulations de la Section 5 suggèrent un régime $\varepsilon_n(\sigma) \sim C(\sigma)/\sqrt{n}$ pour le Cas 1 ; l'établissement d'une borne minimax analogue pour le Cas 2, via les outils

de l'estimation dans les problèmes inverses [2], constituerait la principale contribution théorique restante de ce projet.

7.2 Étude numérique : reconstruction 2D oracle

On illustre numériquement les difficultés spécifiques du Cas 2 dans un cadre *oracle* où les angles Z_i sont supposés connus. Ce cadre simplifié — la reconstruction se réduit à un unique système linéaire, sans étape E — suffit à mettre en évidence la nécessité de la régularisation.

Paramètres. Le fantôme est une image 32×32 ($d = 1024$) représentant un disque avec deux inclusions d'intensités différentes (Fig. 6, panneau gauche), analogue d'une coupe moléculaire. Les $K = 40$ angles sont uniformément répartis sur $[0, 180[$, chacun fournissant $p = 32$ mesures, soit $n_{\text{obs}} = 1280$ observations (rapport $n_{\text{obs}}/d \approx 1,2$). Le bruit est intentionnellement faible ($\sigma = 0,05$) afin d'isoler l'effet du mauvais conditionnement.

Spectre de $A^\top A$ et mauvais conditionnement. La Figure 5 compare le spectre de $A^\top A$ en Cas 2 au spectre constant du Cas 1.




FIGURE 5 – Valeurs propres triées de $A^\top A$ en Cas 2 (Radon, courbe bleue) et en Cas 1 (tirets rouges, $\mu_j = p = 32$ constant). L'axe vertical est logarithmique.

En Cas 1, $A_z^\top A_z = p \text{ Id}_d$ quelle que soit la translation z , donc $A^\top A$ est un multiple de l'identité (conditionnement 1). En Cas 2, les valeurs propres décroissent de $\mu_1 \approx 1138$ à $\mu_d \approx 7,6 \times 10^{-4}$, soit un conditionnement $\text{cond}(A^\top A) \approx 1,5 \times 10^6$. Cette décroissance est la signature discrète du spectre en $|\xi|^{-1}$ de $P^\top P$ (Section 7.1) : les fréquences spatiales élevées de θ sont très faiblement mesurées par les projections, et leur reconstruction amplifie le bruit d'un facteur $\mu_1/\mu_d \approx 10^6$.

Reconstruction Cas 2 — oracle ($n_z = 40$ angles, $\sigma = 0.05$)




FIGURE 6 – Reconstruction oracle en Cas 2 ($K = 40$ angles, $\sigma = 0,05$). De gauche à droite : image vraie θ , reconstruction sans régularisation (erreur 33%), reconstruction Tikhonov $\lambda = 150$ (erreur 7%).

Comparaison des reconstructions. La Figure 6 illustre la dégradation causée par le mauvais conditionnement. Sans régularisation, la reconstruction présente de forts artefacts haute fréquence et une erreur relative de 33% malgré $\sigma = 0,05$: l'inversion directe amplifie les composantes du résidu $Y - A\hat{\theta}$ dans les directions propres de faibles valeurs propres. Avec la régularisation de Tikhonov (20) et $\lambda = 150$, les structures principales du fantôme sont retrouvées avec une erreur réduite à 7%.




FIGURE 7 – Erreur de reconstruction $\|\hat{\theta}(\lambda) - \theta\|/\|\theta\|$ en fonction de λ (Cas 2, oracle). La courbe en U contraste avec la courbe plate du Cas 1 (Figure 4).

Courbe en U et sélection de λ . La Figure 7 montre la courbe en U caractéristique des problèmes inverses régularisés. Pour $\lambda \ll \lambda^*$, l'inversion est instable : la haute variance domine. Pour $\lambda \gg \lambda^*$, la régularisation impose un biais excessif et l'estimateur converge vers zéro. Le minimum est atteint en $\lambda^* \approx 137$ avec une erreur de 7%, à comparer à 33% sans régularisation — réduction d'un facteur 4,8.

Ce résultat contraste directement avec celui de la Section 6.6 (Cas 1, Figure 4) où la courbe était plate sur plusieurs décades de λ . La différence est entièrement expliquée

par l'interprétation spectrale (Section 6.4) : en Cas 1, toutes les valeurs propres de $M^{(k)}$ sont égales à p , donc aucune direction n'est amplifiée par l'inversion et la régularisation n'apporte rien. En Cas 2, les directions propres telles que $\mu_j \ll \lambda^* \sigma^2$ sont celles pour lesquelles la régularisation est décisive, et ce sont précisément celles que le spectre en $|\xi|^{-1}$ rend instables.

Conclusion

Références

- [1] Stephen Boyd and Lieven Vandenberghe. *Convex Optimization*. Cambridge University Press, Cambridge, 2004. URL <https://web.stanford.edu/~boyd/cvxbook/>.
- [2] Laure Cavalier. Nonparametric statistical inverse problems. *Inverse Problems*, 24(3) :034004, 2008. doi : 10.1088/0266-5611/24/3/034004.
- [3] Arthur P. Dempster, Nan M. Laird, and Donald B. Rubin. Maximum likelihood from incomplete data via the EM algorithm. *Journal of the Royal Statistical Society : Series B*, 39(1) :1–22, 1977. doi : 10.1111/j.2517-6161.1977.tb01600.x.
- [4] Joachim Frank. *Three-Dimensional Electron Microscopy of Macromolecular Assemblies : Viewing the Machinery of Life*. Oxford University Press, Oxford, 2 edition, 2006. doi : 10.1093/acprof:oso/9780195182187.001.0001.
- [5] Frank Natterer. *The Mathematics of Computerized Tomography*. Classics in Applied Mathematics. SIAM, Philadelphia, PA, 2001. doi : 10.1137/1.9780898719284.
- [6] Amit Singer and Yoel Shkolnisky. Three-dimensional structure determination from common lines in cryo-EM by eigenvectors and semidefinite programming. *SIAM Journal on Imaging Sciences*, 4(2) :543–572, 2011. doi : 10.1137/090767777.
- [7] C. F. Jeff Wu. On the convergence properties of the EM algorithm. *The Annals of Statistics*, 11(1) :95–103, 1983. doi : 10.1214/aos/1176346060.