

Université Paris Cité
M1 Mathématiques, Données et Apprentissage

Modélisation du schéma de Nesterov par une équation différentielle du second ordre

Reshma MOHANE

Sous le tutorat de M. Yves Capdeboscq

**D'après l'article : A differential equation for modeling
Nesterov's Accelerated Gradient Method**

By Weijie Su, Stephen Boyd and Emmanuel J. Candès

2023-2024

Table des matières

1	Algorithme de Nesterov.	4
1.1	Optimisation sans contraintes	4
1.2	Descente de gradient	5
1.3	Algorithme de Nesterov	5
1.4	Schéma de Nesterov sur des fonctions fortement convexes . . .	6
2	Equation différentielle du second ordre.	9
2.1	Contexte et définitions	9
2.2	Propriété de l'EDO	18
2.3	Solution de l'EDO	22
2.4	Fluctuation d'une fonction fortement convexe	24
2.4.1	La constante 3	24
2.4.2	High friction	25
2.4.3	Low Frictions	26
3	Simulations Numériques.	30
3.1	Pseudos codes	30
3.2	Exemples numériques	31

Introduction

Le Machine Learning est une branche de l'intelligence artificielle qui permet aux machines d'apprendre de manière autonome, en prenant en compte une grande quantité de données, à les trier et à ressortir ce qu'elles jugent nécessaire. Par exemple, la reconnaissance vocale, et les recommandations de musiques sur des plateformes de streaming musicales sont le fruit de l'apprentissage autonome. Ce processus a deux manières de fonctionner, soit par apprentissage supervisé soit par apprentissage non supervisé.

L'optimisation est un outil mathématique primordial qui permet l'apprentissage supervisé de la machine. En effet, elle modélise un problème mathématique de minimisation d'une fonction différentiable, appelé fonction coût qui consiste à mesurer les erreurs entre les prédictions et les données. Le but de ce mémoire est donc d'étudier des manières de minimiser la fonction coût notamment grâce à un célèbre algorithme d'optimisation, l' **Algorithme de Nesterov**, appelé également la Méthode de gradient Accéléré de Nesterov. Cet algorithme a été découvert par le chercheur russe, **Yurii Nesterov** en 1983, mais est resté de nombreuses années dans l'ombre avant de refaire surface dans les années 2000.

Les chercheurs **Weijie Su**, **Stephen Boyd** et **Emmanuel J. Candès** se sont penchés sur l'étude de cet algorithme en introduisant une équation différentielle du second ordre qui le modélise, permettant ainsi de mieux le comprendre. C'est d'ailleurs le sujet de ce mémoire. En effet, dans un premier temps, nous aborderons l'étude de l'algorithme de Nesterov plus en détails. Dans un second temps, nous étudierons la capacité qu'à l'équation différentielle à modéliser l'algorithme correctement. Enfin, nous finirons par illustrer les premières parties à travers des simulations numériques.

Remerciements

Je souhaiterais remercier, sincèrement, M.Y Capdeboscq, professeur à l'Université Paris Cité et tuteur de ce projet pour la pédagogie et la bienveillance dont il a fait preuve durant tout ce semestre. En effet, ayant été mon enseignant d'Analyse et d'Optimisation en licence, il m'a toujours apporté son soutien et ses encouragements, et ceux même durant ce projet tutoré. M. Capdeboscq m'a permis de m'épanouir dans les Mathématiques Appliquées, ce qui m'a poussé à m'inscrire dans le master actuel. Durant ce projet, il a été un tuteur disponible, et faisant preuve de beaucoup de patience sans une once de jugement dans ses conseils, critiques et explications. Voici donc ce mémoire, qui je l'espère, satisfera mon tuteur et le lecteur.

Je remercie également Olivier Bouet Willaumez, qui m'a apporté son soutien tout au long de ce mémoire et qui m'a initié au langage Latex. Je le remercie également pour ses nombreuses relecture du mémoire.

1 Algorithme de Nesterov.

1.1 Optimisation sans contraintes

L'optimisation mathématiques est un domaine des mathématiques qui consiste à modéliser un problème de minimisation d'une fonction différentiable sur un espace hilbertien. On le note :

$$\inf_{x \in E} f(x)$$

avec $f : E \mapsto \mathbb{R}$ différentiable sur E , que l'on appellera fonction de coût ou fonction objective. On supposera, pour la suite, que $E = \mathbb{R}^n$.

On cherche alors à savoir si le problème d'optimisation admet une solution notamment grâce à la continuité et la coercivité de la fonction coût sur un ensemble fermé non vide. On souhaite également savoir si cette solution est unique grâce à la stricte convexité de f . Enfin, nous pourrions déterminer si elle est globale ou locale. On rappelle les définitions suivantes :

Définition : Une solution x est un minimum local de f sur E si :

$$\exists r > 0 \quad \forall y \in E \cap \mathcal{B}(x, r) \quad f(y) \geq f(x)$$

Définition : Une solution x est un minimum global de f sur E si :

$$\forall y \in E \quad f(y) \geq f(x)$$

Dans le cadre de ce mémoire, nous supposons que f admet un unique minimum et est convexe sur E au minimum c'est à dire, telle que :

$$\forall x, y \in E, \quad f(y) \geq f(x) + \langle \nabla f(x), y - x \rangle$$

Conventions :

$\mathcal{F}_L$: Classe de fonction convexe, à gradient L - Lipschitz, continues et définies sur $\mathbb{R}^n$.

$\mathcal{S}_\mu$: Classe des fonctions μ -fortement convexe à gradient continu.

$\mathcal{S}_{\mu,L} = \mathcal{F}_L \cap \mathcal{S}_\mu$: Classe de fonction fortement convexe à gradient L - Lipschitz.

On notera f^* pour désigner $f(x^*)$

1.2 Descente de gradient

L'algorithme de descente de gradient est un algorithme du premier ordre qui permet de résoudre un problème d'optimisation de manière approchée. On suppose que f est une fonction C^2 , différentiable, convexe et admettant un unique minimum global sur E . Il est alors possible de définir un algorithme de descente de gradient à pas fixe, à pas optimal, et à pas d'Armijo par exemple. Cependant, nous allons seulement présenter celui à pas optimal, qui est défini par :

$$\begin{cases} d^{(k)} = -\nabla f(x^{(k)}), \\ t^{(k)} \in \underset{t \in \mathbb{R}}{\operatorname{argmin}} f(x^{(k)} + td^{(k)}), \\ x^{(k+1)} = x^{(k)} + t^{(k)}d^{(k)} \end{cases}$$

Plus particulièrement, pour une fonctionnelle quadratique définie par $f(x) = \frac{1}{2}\langle Ax, x \rangle - \langle b, x \rangle + c$, où A est une matrice carrée $\mathbb{M}_{n,n}(\mathbb{R})$, l'algorithme de descente de gradient à pas optimal s'écrit de la manière suivante :

$$\begin{cases} d^{(k)} = -(Ax^{(k)} - b), \\ t^{(k)} = \begin{cases} \frac{\langle d^{(k)}, d^{(k)} \rangle}{\langle Ad^{(k)}, d^{(k)} \rangle} & \text{si } d^{(k)} \neq 0, \\ 0 & \text{sinon,} \end{cases} \\ x^{(k+1)} = x^{(k)} + t^{(k)}d^{(k)} \end{cases}$$

1.3 Algorithme de Nesterov

Bien que les méthodes de gradient du premier ordre ne soient pas très coûteuses, leur vitesse de convergence assez lente constitue principalement les limites de leur algorithme. C'est pourquoi, Yuri Nesterov introduit en 1983, un algorithme de descente de gradient accéléré du premier ordre, auquel il donne son nom, qui permet notamment une convergence plus rapide que celle des méthodes de gradient classique tout en ayant un faible coût d'implémentation. Elle s'applique à des fonctions convexes au minimum, ce qui est le cas dans le cadre de ce mémoire et est défini par :

$$\begin{cases} x_k = y_{k-1} - s\nabla f(y_{k-1}) \\ y_k = x_k + \frac{k-1}{k+2}(x_k - x_{k-1}) \end{cases}$$

Ce schéma converge :

$$f(x_k) - f(x^*) \leq \mathcal{O}\left(\frac{\|x_0 - x^*\|^2}{sk^2}\right)$$

Le schéma de Nesterov est l'une des méthodes les plus rapides parmi ceux du premier ordre. Par comparaison, les autres méthodes de gradient ont la même complexité que celui-ci mais avec un taux de convergence assez lent c'est à dire de l'ordre de $\mathcal{O}(\frac{1}{k})$. De plus, cet algorithme permet de s'affranchir des potentielles perturbations présentes autour de la solution du problème notamment grâce à son coefficient de momentum choisit : $\frac{k-1}{k+2}$. Des oscillations sont donc présentes tout au long de la trajectoire des itérés qui approchent le minimum. A présent, nous pouvons nous demander si cet algorithme peut également s'appliquer à des fonctions fortement convexes et si cela produit des résultats satisfaisant.

1.4 Schéma de Nesterov sur des fonctions fortement convexes

Une fonction μ -fortement convexe sur C est une fonction $f : \mathbb{R}^n \rightarrow \mathbb{R}$ continue et convexe sur $C \subset \mathbb{R}^n$ telle que $f - \frac{m}{2}\|\cdot\|^2$ soit convexe sur C . La forte convexité implique la stricte convexité et la coercité de f . Ainsi, f admet donc un minimum local, qui sera global et unique sur $\mathbb{R}^n$. On peut donc s'intéresser à l'application du schéma de Nesterov sur ce type de fonction.

Théorème 1 : $\forall f \in S_{\mu,L}(\mathbb{R}^n)$, pour $2 \leq \alpha \leq \frac{2r}{3}$, on a

$$f(X(t)) - f(x^*) \leq \mathcal{O}\left(\frac{\|x_0 - x^*\|^2}{\mu^{(\alpha-2)/2}}\right) \quad \forall t > 0$$

où C dépend de α et de r .

Preuve : Pour démontrer ce théorème, nous introduisons une énergie définie de la manière suivante :

Soit $f \in S_{\mu}(\mathbb{R}^n)$, $\alpha > 2$,

$$\varepsilon(t, \alpha) = t^\alpha(f(X(t)) - f(x^*)) + \frac{(2r - \alpha)^2 t^{\alpha-2}}{8} \|X(t) + \frac{2t}{2t - \alpha} \dot{X} - x^*\|^2$$

On la dérive afin de pouvoir étudier sa monotonie :

$$\begin{aligned}\dot{\varepsilon}(t, \alpha) &= \alpha t^{\alpha-1}(f(X) - f^*) - \frac{(2r - \alpha)t^{\alpha-1}}{2} \langle X - x^*, \nabla f(X) \rangle \\ &\quad + \frac{(\alpha - 2)(2r - \alpha)^2 t^{\alpha-3}}{8} \|X - x^*\|^2 \\ &\quad + \frac{(\alpha - 2)(2r - \alpha)t^{\alpha-2}}{4} \langle \dot{X}, X - x^* \rangle .\end{aligned}$$

Or par la forte convexité de f il vient que :

$$\begin{aligned}\frac{(2r - \alpha)t^{\alpha-1}}{2} \langle X - x^*, \nabla f(X) \rangle &\geq \frac{(2r - \alpha)t^{\alpha-1}}{2} (f(X) - f^*) \\ &\quad + \frac{\mu(2r - \alpha)t^{\alpha-1}}{4} \|X - x^*\|^2 .\end{aligned}$$

Donc on obtient :

$$\begin{aligned}\dot{\varepsilon}(t) &\leq \frac{-(2\mu(2r - \alpha)t^2 - (\alpha - 2)(2r - \alpha)^2)t^{\alpha-3}}{8} \|X - x^*\|^2 \\ &\quad + \frac{(\alpha - 2)(2r - \alpha)t^{\alpha-2}}{8} \frac{d}{dt} \|X - x^*\|^2 .\end{aligned}$$

Si $t \geq t_\alpha = \sqrt{\frac{(\alpha-2)(2r-\alpha)}{2\mu}}$ alors on obtient :

$$\dot{\varepsilon}(t) \leq \frac{(\alpha - 2)(2r - \alpha)t^{\alpha-2}}{8} \frac{d}{dt} \|X - x^*\|^2 .$$

On intègre sur $]t_\alpha, t[$ et on obtient :

$$\int_{t_\alpha}^t \dot{\varepsilon}(t) \, dt \leq \int_{t_\alpha}^t \frac{(\alpha - 2)(2r - \alpha)t^{\alpha-2}}{8} \frac{d}{dt} \|X - x^*\|^2 \, dt$$

On effectue une intégration par partie :

$$\int u'v = [uv] - \int uv'$$

où $u' = \frac{d}{dt} \|X - x^*\|^2$ donc $u = \|X - x^*\|^2$ et $v = t^{\alpha-2}$ donc $v' = (\alpha - 2)t^{\alpha-3}$.

$$\begin{aligned}
\varepsilon(t) - \varepsilon(t_\alpha) &\leq C_\alpha([t^{\alpha-2}\|X - x^*\|^2]_{t_\alpha}^t - \int_{t_\alpha}^t (\alpha - 2)t^{\alpha-2}\|X - x^*\|^2) \\
&\Leftrightarrow \varepsilon(t) - \varepsilon(t_\alpha) \leq C_\alpha t^{\alpha-2}\|X(t) - x^*\|^2 - C_\alpha t^{\alpha-2}\|X(t_\alpha) - x^*\|^2 \\
&\quad - C_\alpha t^{\alpha-2} \int_{t_\alpha}^t (\alpha - 2)u^{\alpha-2}\|X(u) - x^*\|^2 du \\
&\Leftrightarrow \varepsilon(t) \leq \varepsilon(t_\alpha) + C_\alpha t^{\alpha-2}\|X(t) - x^*\|^2 \\
&\Leftrightarrow \varepsilon(t) \leq \varepsilon(t_\alpha) + C_\alpha t^{\alpha-2}(f(X(t)) - f^*).
\end{aligned}$$

avec

$$C_\alpha = \frac{(\alpha - 2)(2r - \alpha)}{8}$$

Nous verrons la fin de ce théorème, à la fin de la seconde partie car des outils mathématiques utiles y seront démontrés.

Théorème 2 : On suppose que $f = g + h$ où $g \in S_{\mu,L}(\mathbb{R}^n)$ et h convexe.

Alors le schéma de Nesterov discret s'écrit :

$$\begin{cases} x_k = y_{k-1} - sG_s(y_{k-1}) \\ y_k = x_k + \frac{k-1}{k+r-1}(x_k - x_{k-1}) \end{cases}$$

satisfait $f(x_k) - f^* \leq \frac{CL\|x_0 - x^*\|^2}{k^2} \frac{\sqrt{L/\mu}}{k}$ où C dépend uniquement de r et G désigne l'ensemble des tangentes en x .

Donc le théorème dit que le schéma a une vitesse de convergence de l'ordre de $\mathcal{O}(\frac{1}{k^3})$.

Preuve : Admis

On remarque donc que le schéma de Nesterov appliqué à une fonction μ - fortement convexe ne converge pas aussi rapidement que les fonctions strictement convexes. En effet, pour se faire il faudrait connaître la constante de forte convexité μ , donc l'ensemble des valeurs propres de la hessienne de f . Cependant, à grande échelle il peut s'avérer difficile de les déterminer voir même impossible. C'est pourquoi, les chercheurs de cet article se sont penchés sur une solution qui peut permettre d'avoir des résultats satisfaisant pour des fonctions fortement convexe sans avoir recours à leur ensembles de valeurs propres.

2 Equation différentielle du second ordre.

2.1 Contexte et définitions

L'algorithme de Nesterov est resté pendant de nombreuses années dans l'ombre, bien que les chercheurs avaient conscience de cette découverte. Ce n'est que tardivement, au travers de l'article étudié qu'on se rend compte de la manière dont le schéma fonctionne notamment en le modélisant grâce à une équation différentielle ordinaire du second ordre, qui se définit par :

$$\begin{cases} X'' + \frac{3}{t}X' + \nabla f(X) = 0 \\ X(0) = x_0 \\ X'(0) = 0 \end{cases}$$

$\forall t > 0$ avec $X' = \frac{dX}{dt}$ qui correspond à la vitesse et $X'' = \frac{d^2X}{dt^2}$ qui correspond à l'accélération.

Ainsi, nous étudierons dans ce chapitre différents aspects de cette EDO qui nous permettront d'expliquer le comportement du schéma de Nesterov. Dans l'EDO, $t \approx k\sqrt{s}$ et donc l'EDO converge :

$$f(X(t)) - f(x^*) \leq \mathcal{O}\left(\frac{\|x_0 - x^*\|^2}{t^2}\right)$$

Rappel : Soit $L > 0$. On dit qu'une fonction est L - Lipschitzienne si elle vérifie $\forall x, y \in \mathbb{R}^n$:

$$\|\nabla f(x) - \nabla f(y)\|_2 \leq L\|x - y\|_2$$

On souhaite déterminer le lien entre l'EDO et l'algorithme de Nesterov. Pour cela, on applique le schéma à une fonction f telle que $f \in \mathcal{F}_L$ alors :

$$\begin{cases} x_k = y_{k-1} - s\nabla f(y_{k-1}) \\ y_k = x_k + \frac{k-1}{k+2}(x_k - x_{k-1}) \end{cases}$$

À la ligne 1 du schéma, on commence par isoler x_{k+1} :

$$x_{k+1} = y_k - s\nabla f(y_k) = x_k + \frac{k-1}{k+2}(x_k - x_{k-1}) - s\nabla f(y_k)$$

Ensuite, il vient que :

$$\begin{aligned} x_{k+1} - x_k &= \frac{k-1}{k+2}(x_k - x_{k-1}) - s\nabla f(y_k) \\ \Leftrightarrow \frac{x_{k+1} - x_k}{\sqrt{s}} &= \frac{k-1}{k+2} \frac{(x_k - x_{k-1})}{\sqrt{s}} - \frac{s}{\sqrt{s}} \nabla f(y_k) \\ \Leftrightarrow \frac{x_{k+1} - x_k}{\sqrt{s}} &= \frac{k-1}{k+2} \frac{(x_k - x_{k-1})}{\sqrt{s}} - \sqrt{s} \nabla f(y_k) \end{aligned}$$

Donc on obtient finalement :

$$\frac{x_{k+1} - x_k}{\sqrt{s}} = \frac{k-1}{k+2} \frac{x_k - x_{k-1}}{\sqrt{s}} - \sqrt{s} \nabla f(y_k) \quad (1)$$

En introduisant $x_k \approx X(k\sqrt{s})$, pour $X(t)$ définit $\forall t \geq 0$. Si $k = \frac{t}{\sqrt{s}}$ alors $X(t) \approx x_{t/\sqrt{s}} = x_k$ pour $s \rightarrow 0$ et $X(t + \sqrt{s}) \approx x_{(t+\sqrt{s})/\sqrt{s}} = x_{k+1}$.

On effectue un développement de Taylor à l'ordre 2 :

$$\begin{aligned} \frac{x_{k+1} - x_k}{\sqrt{s}} &= X(0) + X'(t) + \frac{1}{2}X''(t)\sqrt{s} + o(\sqrt{s}) \\ &= X'(t) + \frac{1}{2}X''(t)\sqrt{s} + o(\sqrt{s}) \end{aligned}$$

On a alors :

$$\frac{x_k - x_{k-1}}{\sqrt{s}} = X'(t) - \frac{1}{2}X''(t)\sqrt{s} + o(\sqrt{s})$$

On réécrit le 1 par :

$$X'(t) + \frac{1}{2}X''(t)\sqrt{s} + o(\sqrt{s}) = \frac{k-1}{k+2}(X'(t) - \frac{1}{2}X''(t)\sqrt{s} + o(\sqrt{s})) - \sqrt{s}\nabla f(y_k).$$

Or :

$$\begin{aligned} \frac{k-1}{k+2} &= \frac{t/\sqrt{s} - 1}{t/\sqrt{s} + 2} = \frac{(t - \sqrt{s})/\sqrt{s}}{(t + 2\sqrt{s})/\sqrt{s}} \\ &= \frac{t - \sqrt{s}}{\sqrt{s}} \frac{\sqrt{s}}{t + 2\sqrt{s}} = \frac{(t - \sqrt{s})(t - 2\sqrt{s})}{(t + 2\sqrt{s})(t - 2\sqrt{s})} \\ &= \frac{t^2 - 2t\sqrt{s} - t\sqrt{s} + 2s}{t^2 - 4s} = \frac{t^2 - 3t\sqrt{s} + 2s}{t^2 - 4s} \\ &= 1 - \frac{3}{t}\sqrt{s}. \end{aligned}$$

Donc :

$$\begin{aligned}
X'(t) + \frac{1}{2}X''(t)\sqrt{s} + o(\sqrt{s}) &= (1 - \frac{3}{t}\sqrt{s})(X'(t) - \frac{1}{2}X''(t)\sqrt{s} + o(\sqrt{s})) \\
&\quad - \sqrt{s}\nabla f(y_k) \\
\Leftrightarrow \frac{3}{t}\sqrt{s}X'(t) + X''(t)\sqrt{s} + \frac{3}{2t}\sqrt{s}X''(t)\sqrt{s} + \sqrt{s}\nabla f(y_k) &= 0.
\end{aligned}$$

On factorise par $\sqrt{s}$ et on obtient bien :

$$X'' + \frac{3}{t}X' + \nabla f(X) = 0$$

et les conditions initiales sont bien vérifiées. On vient donc de montrer comment que l'EDO découle en réalité directement du schéma de Nesterov.

Par ailleurs, un autre choix de coefficient de momentum est $\theta_k(\frac{1}{\theta_{k-1}-1})$ où θ_k est défini par :

$$\begin{cases} \theta_{k-1} = (\sqrt{\theta_k^4 + 4\theta_k^2} - \theta_k^2)/2 \\ \theta_0 = 1 \end{cases}$$

On remarque que ainsi défini $\theta_k(\frac{1}{\theta_{k-1}-1})$ est asymptotiquement égal à $1 - \frac{3}{k} + o(\frac{1}{k^2})$ ce qui mène à l'EDO. Nous venons donc d'expliquer en quoi elle modélise bien le schéma de Nesterov. A présent, on peut donc étudier, au travers d'un théorème fondamental de ce mémoire, l'existence et l'unicité de la solution de cette EDO.

Théorème 3 : $\forall f \in \mathcal{F}_\infty = \bigcup_{L>0} \mathcal{F}_L$ et $x_0 \in \mathbb{R}^n$, l'EDO possède une unique solution globale $x \in C^2([0, \infty], \mathbb{R}^n) \cap C^1([0, \infty], \mathbb{R}^n)$.

Preuve : Dans un premier temps, nous allons démontrer l'existence de cette solution.

Lemme 1 : $\forall f \in \mathcal{F}_\infty$ et $x_0 \in \mathbb{R}^n$, l'EDO a au moins une solution qui appartient à $C^2([0, \infty], \mathbb{R}^n) \cap C^1([0, \infty], \mathbb{R}^n)$.

Preuve du lemme 1 : On considère l'EDO :

$$\begin{cases} X'' + \frac{3}{\max(\delta, t)} X' + \nabla f(X) = 0 \\ X(0) = x_0 \\ X'(0) = 0 \end{cases}$$

On pose $Z = X'$, alors :

$$\begin{pmatrix} \frac{dX}{dt} \\ \frac{dZ}{dt} \end{pmatrix} = \begin{pmatrix} Z \\ \frac{-3}{\max(\delta, t)} Z - \nabla f(X) \end{pmatrix}$$

avec $X(0) = x_0$ et $Z(0) = 0$.

En tant que fonction de (X, Z) , Z et $\frac{-3}{\max(\delta, t)} Z$ sont $(\max(1, L) + \frac{3}{\delta})$ - Lipschitzienne (admis). Alors d'après le théorème de Cauchy Lipschitz global, il existe une unique solution qui appartient à $C^0[0, \infty]$ qu'on note X_δ . On remarque que X_δ'' est aussi définie pour $t = 0$.

Soit $M_\delta(t)$ le sup de $\frac{\|X_\delta'(u)\|}{u} \quad \forall u \in [0, t]$. On remarque que $M_\delta(t)$ est finit car $\frac{\|X_\delta'(u) - X_\delta'(0)\|}{u} = \|X_\delta''(0)\| + o(1)$. On cherche donc une limite supérieure pour $M_\delta(t)$. On distingue alors les cas :

Pour $0 \leq t \leq \delta$:

Lemme 2 : Pour $\delta < \sqrt{6/L}$,

$$M_\delta(\delta) \leq \frac{\|\nabla f(x_0)\|}{1 - L\delta^2/6}$$

Pour prouver ce lemme, nous aurons besoin du lemme suivant.

Lemme 3 : $\forall u > 0$

$$\|\nabla f(X_\delta(u)) - \nabla f(x_0)\| \leq \frac{1}{2} L M_\delta(u) u^2$$

Preuve : Puisque $f \in \mathcal{F}_\infty$ alors il existe L tel que $f \in \mathcal{F}_L$ donc ∇f est L - Lipschitz :

$$\begin{aligned}
\|\nabla f(X_\delta(u)) - \nabla f(x_0)\| &\leq \|X_\delta(u) - x_0\| = L \left\| \int_0^u X'_\delta(v) dv \right\| \\
&\leq L \int_0^u v \frac{\|X'_\delta(v)\|}{v} dv = \left[\frac{1}{2} v^2 \frac{\|X'_\delta(v)\|}{v} \right]_0^u - \dots \\
&= L \frac{1}{2} u^2 M_\delta(u) \quad \text{par une IPP.}
\end{aligned}$$

Or d'après le **lemme 3** :

$$\begin{aligned}
\frac{\|X'_\delta(t)\|}{t} &= \frac{1}{t} e^{-3u/\delta} \|\nabla f(x_0)\| \int_0^t e^{3u/\delta} du + \frac{1}{t} e^{-3u/\delta} \int_0^t \frac{1}{2} u^2 L M_\delta(u) e^{3u/\delta} du \\
&\leq \|\nabla f(x_0)\| + \frac{L M_\delta(\delta) \delta^2}{6} \\
&\Leftrightarrow M_\delta(\delta) \leq \|\nabla f(x_0)\| + \frac{L M_\delta(\delta) \delta^2}{6} \\
&\Leftrightarrow M_\delta(\delta) - \frac{L M_\delta(\delta) \delta^2}{6} = M_\delta(\delta) \left(1 - \frac{L \delta^2}{6}\right) \leq \|\nabla f(x_0)\| \\
&\Leftrightarrow M_\delta(\delta) \leq \frac{\|\nabla f(x_0)\|}{1 - L \delta^2/6}
\end{aligned}$$

est bien défini car $\delta < \sqrt{6/L}$, donc le dénominateur n'est jamais nul.

Pour $\delta < t < \sqrt{12/L}$:

Lemme 4 : Soit $\delta < \sqrt{\frac{6}{L}}$,

$$M_\delta(\delta) = \frac{(5 - L \delta^2/6) \|\nabla f(x_0)\|}{4(1 - L \delta^2/6)(1 - L t^2/12)}$$

Preuve : Pour $t > \delta$

$$X''_\delta + \frac{3}{t} X'_\delta + \nabla f(X_\delta) = 0$$

qui est équivalent à :

$$\frac{dt^3 X'_\delta(t)}{dt} = -t^3 \nabla f(X_\delta(t))$$

On intègre cette égalité grâce à une IPP :

$$\begin{aligned}
\int_{\delta}^t \frac{dt^3 X'_{\delta}(t)}{dt} &= [u^3 X'_{\delta}(\delta)]_{\delta}^t - \int_{\delta}^t u^3 \nabla f(X_{\delta}(u)) du \\
\Leftrightarrow \int_{\delta}^t \frac{dt^3 X'_{\delta}(t)}{dt} &= \delta^3 X'_{\delta}(\delta) - \int_{\delta}^t u^3 \nabla f(X_{\delta}(u)) du \\
\Leftrightarrow \int_{\delta}^t \frac{dt^3 X'_{\delta}(t)}{dt} &= \delta^3 X'_{\delta}(\delta) - \int_{\delta}^t u^3 \nabla f(x_0) du \\
&\quad - \int_{\delta}^t u^3 (\nabla f(X_{\delta}(u)) - \nabla f(x_0)) du
\end{aligned}$$

Par conséquent en intégrant $\int_{\delta}^t \frac{dt^3 X'_{\delta}(t)}{dt}$ et par les **lemmes 2 et 3**, nous obtenons :

$$\begin{aligned}
\frac{\|X'_{\delta}(t)\|}{t} &\leq \|\nabla f(x_0)\| \frac{t^4 - \delta^4}{4t^4} + \frac{1}{t^4} \int_{\delta}^t \frac{1}{2} L M_{\delta}(u) u^5 du + \frac{\delta^4}{t^4} \frac{\|X'_{\delta}(t)\|}{\delta} \\
\Leftrightarrow \frac{\|X'_{\delta}(t)\|}{t} &\leq \frac{1}{4} \|\nabla f(x_0)\| + \frac{1}{12} L M_{\delta}(t) t^2 + \frac{\|\nabla f(x_0)\|}{1 - L\delta^2/6}.
\end{aligned}$$

qui est une fonction croissante en t , donc $\forall \delta < t' < t$, on a :

$$\frac{\|X'_{\delta}(t)\|}{t'} \leq \frac{1}{4} \|\nabla f(x_0)\| + \frac{1}{12} L M_{\delta}(t) t^2 + \frac{\|\nabla f(x_0)\|}{1 - L\delta^2/6}$$

En prenant le supremum pour $t' \in]0, t[$, on obtient :

$$\begin{aligned}
\Leftrightarrow M_{\delta}(t) &\leq \frac{1}{4} \|\nabla f(x_0)\| + \frac{1}{12} L M_{\delta}(t) t^2 + \frac{\|\nabla f(x_0)\|}{1 - L\delta^2/6} \\
\Leftrightarrow M_{\delta}(t) - \frac{1}{12} L M_{\delta}(t) t^2 &\leq \frac{\|\nabla f(x_0)\| (1 - L\delta^2/6) + 4 \|\nabla f(x_0)\|}{12(1 - L\delta^2/6)} \\
\Leftrightarrow M_{\delta}(t) (1 - \frac{1}{12} L t^2) &\leq \frac{5 \|\nabla f(x_0)\| - L\delta^2/6 \|\nabla f(x_0)\|}{12(1 - L\delta^2/6)} \\
\Leftrightarrow M_{\delta}(t) &\leq \frac{(5 - L\delta^2/6) \|\nabla f(x_0)\|}{4(1 - L\delta^2/6)(1 - Lt^2/12)}
\end{aligned}$$

bien défini car le dénominateur ne s'annule jamais puisque $\delta < t < \sqrt{12/L}$ et $\delta < \sqrt{\frac{6}{L}}$.

Lemme 5 : La classe de fonctions

: est uniformément bornée et équicontinue.

Preuve : D'après les **lemmes 2** et **4**, $\forall t \in]0, \sqrt{6/L}[$ et $\delta \in]0, \sqrt{3/L}[$, le gradient est uniformément borné de telle sorte que :

$$\begin{aligned}
X'_\delta(t) &\leq \sqrt{6/L} M_\delta(\sqrt{6/L}) \\
&\leq \sqrt{6/L} \max\left(\frac{\|\nabla f(x_0)\|}{1 - L\delta^2/6}, \frac{(5 - L\delta^2/6)\|\nabla f(x_0)\|}{4(1 - L\delta^2/6)(1 - Lt^2/12)}\right) \\
&\leq \sqrt{6/L} \max\left(\frac{\|\nabla f(x_0)\|}{1 - \frac{1}{2}}, \frac{5\|\nabla f(x_0)\|}{4(1 - \frac{1}{2})(1 - \frac{1}{2})}\right) \\
&= \sqrt{6/L} \max\left(2\|\nabla f(x_0)\|, 5\|\nabla f(x_0)\|\right) \\
&= 5\sqrt{6/L}\|\nabla f(x_0)\|
\end{aligned}$$

Donc $\mathcal{F}$ est équicontinue c'est à dire

$$\forall x \in I, \forall \varepsilon > 0, \exists \delta > 0, \forall x \in I, d(x_0, x) < \delta \implies |f(x) - f(x_0)| < \varepsilon$$

Montrons que $\mathcal{F}$ est uniformément bornée :

$$\begin{aligned}
\|X_\delta(t)\| &\leq \|X_\delta(0)\| + \int_0^t \|X'_\delta(u)\| du \\
&\leq \|X_0\| + (5\sqrt{6/L})^2 \|\nabla f(x_0)\| \\
&= \|X_0\| + 30L\|\nabla f(x_0)\|
\end{aligned}$$

Preuve du lemme 1 :

- Par le théorème d'Ascoli et le **lemme 5**, $\mathcal{F}$ contient une sous séquence notée $\{X_{\delta mi}\}$ qui converge uniformément vers $\tilde{X}$.

- $\delta mi = \sqrt{3/L}/2^{mi}$ décroît pour $i \rightarrow \infty$.

- Montrons que $\tilde{X}$ satisfait (3) et $\tilde{X}(0) = x_0$ et $\tilde{X}'(0) = 0$.

On fixe $t_0 \in]0, \sqrt{6/L}[$. Puisqu'on sait que $\|X'_{\delta mi(t_0)}\|$ est bornée, on peut choisir une sous séquence de $X'_{\delta mi(t_0)}$ qui converge vers une limite qu'on notera $\tilde{X}'_{t_0}$. Sans perte de généralité, la sous séquence est aussi la séquence originale.

On note $\check{X}$ la solution locale de (3) avec $X(t_0) = \check{X}(t_0)$ et $X'(t_0) = \check{X}'(t_0)$. On rappelle que $X_{\delta mi}$ est solution de l'EDO $X(t) = X_{\delta mi}(t)$ et $X'(t) = X'_{\delta mi}(t)$ pour $\delta mi < t_0$. Donc $X_{\delta mi}(t_0)$ approche $\check{X}(t_0)$ et $X'_{\delta mi}(t_0)$ approche $\check{X}'(t_0)$.

Alors il existe $\varepsilon_0 > 0$ tel que :

$$\sup_{t_0 - \varepsilon_0 < t < t_0 + \varepsilon_0} \|X_{\delta mi}(t) - \check{X}(t)\| \xrightarrow{i \rightarrow \infty} 0$$

et

$$\sup_{t_0 - \varepsilon_0 < t < t_0 + \varepsilon_0} \|X_{\delta mi}(t) - X(t)\| \xrightarrow{i \rightarrow \infty} 0$$

Par conséquent, $\check{X} = X$ sur $]t_0 - \varepsilon_0, t_0 + \varepsilon_0[$. Donc $\check{X}$ satisfait l'EDO en t_0 mais puisque t_0 est arbitraire, on en conclut que $\check{X}$ est solution de l'EDO sur $]0, \sqrt{6/L}[$.

Par extension, $\check{X}$ peut être une solution globale de l'EDO sur $]0, \infty[$. On commence par vérifier les conditions initiales.

Premièrement, $\check{X}(0) = x_0$ est une conséquence directe de $X_{\delta mi}(0) = x_0$.

Ensuite, on a que :

$$\begin{aligned} \frac{\|\check{X}(t) - \check{X}(0)\|}{t} &= \lim_{i \rightarrow \infty} \frac{\|X_{\delta mi}(t) - \check{X}(0)\|}{t} \\ &= \lim_{i \rightarrow \infty} \|X'_{\delta mi}(t)\| \\ &\leq \lim_{i \rightarrow \infty} \sup t M_{\delta mi}(t) \\ &\leq 5t \sqrt{6/L} \|\nabla f(x_0)\| \xrightarrow{t \rightarrow 0} 0 \end{aligned}$$

Donc on a bien que $\check{X}'(0) = 0$, donc les conditions initiales pour $\check{X}$ sont bien vérifiées.

Lemme 6 : $\forall f \in \mathcal{F}_\infty$, l'EDO a au plus une solution au voisinage de $t = 0$.

On suppose qu'il existe deux solutions X et Y définies sur $]0, \alpha[$ où $\alpha > 0$. On note $M(t)$ le sup de $\|X'(u) - Y'(u)\|$ sur $[0, \alpha[$.

Pour prouver ce lemme, nous aurons besoin du lemme suivant :

Lemme 7 : $\forall t \in]0, \alpha[$,

$$\|\nabla f(X(t)) - \nabla f(Y(t))\| \leq Lt\check{M}(t)$$

Preuve : Le gradient de f est L - Lipschitz donc

$$\begin{aligned} \|\nabla f(X(t)) - \nabla f(Y(t))\| &\leq \|X(t) - Y(t)\| \\ &= L\left\|\int_0^t X'(u) - Y'(u)du + X(0) - Y(0)\right\| \\ &\leq L\int_0^t \|X'(u) - Y'(u)\|du \\ &\leq Lt\check{M}(t) \end{aligned}$$

Preuve du lemme 6 : Montrons qu'il y a au plus une solution :

$$t^3\|X'(t) - Y'(t)\| \leq -\int_0^t u^3 \nabla f(X(u)) - \nabla f(Y(u))du.$$

En appliquant le **lemme 7** :

$$\begin{aligned} t^3\|X'(t) - Y'(t)\| &\leq \int_0^t Lu^4\check{M}(u)du \leq \frac{1}{5}Lt^5\check{M}(t) \\ \Leftrightarrow \|X'(t) - Y'(t)\| &\leq \frac{1}{5}Lt^5\check{M}(t) \quad \forall t' < t \end{aligned}$$

On prend le sup de $\|X'(t) - Y'(t)\| \quad \forall t \in]0, t[\quad \check{M}(t) \leq Lt^5\check{M}(t)$.

Par conséquent, on a $\check{M}(t) = 0 \quad \forall t < \min(\alpha, \sqrt{5/L})$

donc

$$\check{M}(t) = 0 \Leftrightarrow \|X'(u) - Y'(u)\| = 0$$

c'est à dire $X' = Y'$ sur $[0, \min(\alpha, \sqrt{5/L})]$. De plus, $X(0) = Y(0) = x_0$ et $\nabla f(X) = \nabla f(Y)$ donc $X = Y$ sur $]0, \min(\alpha, \sqrt{5/L})]$ ce qui est une contradiction.

2.2 Propriété de l'EDO

Dans cette section, nous allons étudier les propriétés de l'EDO.

Invariante par temps : Pour le démontrer on introduit les notations suivantes :

$$\tilde{t} = ct$$

avec $c > 0$:

$$\frac{dX}{d\tilde{t}} = \frac{1}{c} \frac{dX}{dt}$$

et

$$\frac{dX^2}{d\tilde{t}^2} = \frac{1}{c^2} \frac{d^2X}{dt^2}$$

$$\frac{dX^2}{d\tilde{t}^2} + \frac{3}{\tilde{t}} \frac{dX}{d\tilde{t}} + \frac{\nabla f(X)}{c^2} = 0.$$

On peut remarquer que minimiser $\frac{f}{c^2}$ revient à minimiser f .

En effet :

$$\begin{aligned} & \frac{dX^2}{d\tilde{t}^2} + \frac{3}{\tilde{t}} \frac{dX}{d\tilde{t}} + \frac{\nabla f(X)}{c^2} = 0 \\ \Leftrightarrow & \frac{1}{c^2} \frac{d^2X}{dt^2} + \frac{3}{c^2 t} \frac{dX}{dt} + \frac{\nabla f(X)}{c^2} = 0 \\ \Leftrightarrow & \frac{1}{c^2} \left(\frac{d^2X}{dt^2} + \frac{3}{t} \frac{dX}{dt} + \nabla f(X) \right) = 0 \end{aligned}$$

Donc l'EDO est invariante par temps.

Invariante par rotation : Le schéma de nesterov est invariant par rotation donc montrons que l'EDO est invariante par transformation orthogonale.

Soit $Y = QX$ où Q est une matrice orthogonale. Alors on a $Y' = QX'$ et $Y'' = QX''$ et $\nabla_y f = Q\nabla_x f$. L'EDO devient :

$$\begin{aligned}
& \frac{dX^2}{dt^2} + \frac{3}{t} \frac{dX}{dt} + \frac{\nabla f(X)}{c^2} = 0 \\
& \Leftrightarrow Q^T Y'' + \frac{3}{t} Q^T Y + Q^T \nabla_y f = 0 \quad \text{car } QX = Y \\
& \Leftrightarrow QQ^T Y'' + \frac{3}{t} QQ^T Y + QQ^T \nabla_y f = 0 \\
& \Leftrightarrow Y'' + \frac{3}{t} Y' + \nabla_y f = 0
\end{aligned}$$

car $Q^T = Id$ puisque Q est orthogonale.

Donc l'EDO est bien invariante par rotation.

Initial asymptotic : On suppose que $\lim_{t \rightarrow 0} X''(t)$ existe. Le théorème garantit l'existence de $\zeta \in]0, t[$ tel que $\frac{X'(t)}{t} = \frac{X'(t) - X'(0)}{t} = X''(\zeta)$, alors l'EDO devient :

$$X''(t) + 3X''(\zeta) + \nabla f(X) = 0$$

Et lorsque $t \rightarrow 0$:

$$\begin{aligned}
& X''(0) + 3X''(0) + \nabla f(X) = 0 \\
& \Leftrightarrow 4X''(0) = -\nabla f(x_0) \\
& \Leftrightarrow X''(0) = -\frac{\nabla f(x_0)}{4}
\end{aligned}$$

Donc pour tout t assez petit, $X(t) = -\frac{\nabla f(x_0)}{8}t^2 + C + o(t^2)$.

Pour trouver C , on utilise les conditions initiales :

$$\begin{aligned}
& X(0) = x_0 \\
& \Leftrightarrow -\frac{\nabla f(x_0)}{8}0 + C = x_0
\end{aligned}$$

donc $x_0 = C$.

Alors pour tout t assez petit :

$$X(t) = -\frac{\nabla f(x_0)}{8}t^2 + x_0 + o(t^2).$$

Cela montre d'ailleurs que le schéma de Nesterov converge lentement au début à cause de t^2 .

Théorème : $\forall f \in \mathcal{F}_\infty$, $X(t)$ est l'unique solution globale de l'EDO vérifiant $X(0) = x_0$ et $X'(0) = x_0$.

Alors $\forall t \geq 0$:

$$f(X(t)) - f^* \leq \frac{2\|x_0 - x^*\|^2}{t^2}$$

Preuve : On considère l'énergie suivante :

$$\varepsilon(t) = t^2(f(X(t)) - f^*) + 2\|X + t\frac{X'}{2} - X^*\|^2$$

$\varepsilon(t)$ est une fonction différentiable, on la dérive donc, en particulier la norme présente dans l'énergie, qu'on notera g , afin d'en étudier sa monotonie.

Soit $t, h > 0$:

$$\begin{aligned} 2 \langle X + t\frac{X'}{2} + h\frac{X'}{2} - X^*, X + t\frac{X'}{2} + h\frac{X'}{2} - X^* \rangle &= 2 \langle X, X \rangle \\ &+ 4 \langle X, t\frac{X'}{2} \rangle + 4 \langle X, h\frac{X'}{2} \rangle + 4 \langle X, -X^* \rangle + 2 \langle t\frac{X'}{2}, t\frac{X'}{2} \rangle \\ &+ 4 \langle t\frac{X'}{2}, h\frac{X'}{2} \rangle + 4 \langle t\frac{X'}{2}, -x^* \rangle + 2 \langle h\frac{X'}{2}, h\frac{X'}{2} \rangle + \langle h\frac{X'}{2}, -x^* \rangle \end{aligned}$$

Puisque $Dg_{(x)}(h) = \langle \nabla g(x), h \rangle$ alors ici, par identification :

$$\begin{aligned} \nabla g(x) &= \varepsilon'(t) \\ &= 2t(f(X(t)) - f^*) + t^2 \langle \nabla f, X' \rangle \\ &\quad + 4 \langle X + \frac{t}{2}X' - X^*, \frac{3}{2}X' + \frac{t}{2}X'' \rangle \end{aligned}$$

On remplace $\frac{3}{2}X' + \frac{t}{2}X''$ par $\frac{-t\nabla f(X)}{2}$.

Il vient que :

$$\begin{aligned} \varepsilon'(t) &= 2t(f(X(t)) - f^*) + 4 \langle X - X^*, \frac{-t\nabla f(X)}{2} \rangle \\ &= 2t(f(X(t)) - f^*) - 2t \langle X - X^*, \nabla f(X) \rangle \\ &= 2t((f(X(t)) - f^*) - \langle X - X^*, \nabla f(X) \rangle) \end{aligned}$$

Or $f(X) - f^* \leq \langle X - X^*, \nabla f(X) \rangle$ car X^* est un minimum global de f donc $f^* \geq f(X) - \langle X - X^*, \nabla f(X) \rangle$.

Donc ε' est négative alors ε décroît. Alors par monotonie de ε et la positivité de g on a :

$$f(X(t)) - f^* \leq \frac{\varepsilon(t)}{t^2} \leq \frac{\varepsilon(0)}{t^2} = \frac{2\|x_0 - x^*\|^2}{t^2}$$

Théorème 3 : $\forall f \in \mathcal{F}_\infty$ et $s \rightarrow 0$, le schéma de Nesterov converge vers l'EDO dans le sens où :

$$\forall T > 0 \quad \lim_{s \rightarrow 0} \max_{0 \leq k \leq T/\sqrt{s}} \|x_k - X(k\sqrt{s})\| = 0$$

Preuve : On identifie $\sqrt{s} = \Delta t$ et on observe que le schéma de Nesterov est un schéma discret pour l'intégration numérique de l'EDO. Mais le coefficient d'amortissement présent en $t = 0$ impose une non existence de l'EDO. On utilise alors pour la suite de la preuve, l'EDO suivante :

$$X'' + \frac{3}{\max(\delta, t)} X' + \nabla f(X) = 0$$

pour approximer l'EDO originale. On obtient alors :

$$\begin{cases} X_{k+1}^\delta = X_k^\delta + \Delta t Z_k^\delta \\ Z_{k+1}^\delta = (1 - \frac{3\Delta t}{\max(\delta, k\Delta t)}) Z_k^\delta - \Delta t \nabla f(X_k^\delta) \end{cases}$$

où $X_0^\delta = x_0$ et $Z_0^\delta = 0$.

Lemme 8 : Pour $\sqrt{s} = \Delta t$ on a $\forall T > 0$

$$\max_{1 \leq k \leq T/\sqrt{s}} \|X_k^\delta - x_k\| \leq C\delta^2 + o_s(1)$$

où C est une constante.

Preuve : Admis.

Preuve du théorème :

$$\|x_k - X(k\sqrt{s})\| \leq \|x_k - X_k^\delta\| + \|X_k^\delta - X_\delta(k\sqrt{s})\| + \|X_\delta(k\sqrt{s}) - X(k\sqrt{s})\| \quad (2)$$

où X_δ est solution de l'EDO.

Le **lemme 1** implique que l'on peut choisir une séquence $\delta m \rightarrow 0$ telle que

$$\sup_{0 \leq t \leq T} \|X_{\delta m(t_0)} - X(t)\| \rightarrow 0$$

Le premier et second terme de l'inégalité disparaissent uniformément pour $s \rightarrow 0$ et le troisième également si $\delta m \rightarrow 0$.

Théorème 4 : On suppose $1 < r < 3$ et soit X la solution de l'EDO

$$X'' + \frac{r}{t}X' + \nabla f(X) = 0 \quad (3)$$

Si $(f - f^*)^{\frac{r-1}{2}}$ est convexe alors $f(X(t)) - f^* \leq \frac{(r-1)^2 \|x_0 - x^*\|^2}{2t^2}$.

Preuve : Si $(f - f^*)^{\frac{r-1}{2}}$ est convexe, alors on obtient :

$$\begin{aligned} (f(X(t)) - f^*)^{\frac{r-1}{2}} &\leq \langle X - X^*, \nabla (f - f^*)^{\frac{r-1}{2}} \rangle \\ &= \frac{r-1}{2} (f - f^*)^{\frac{r-3}{2}} \langle X - X^*, \nabla (f(X(t))) \rangle \\ &= \frac{2}{r-1} (f - f^*) \langle X - X^*, \nabla (f(X(t))) \rangle \end{aligned}$$

Combiné à 18, on vient de montrer la décroissance de $\varepsilon(t)$ définit dans le **théorème 5** qui suivra. Donc

$$f(X(t)) - f^* \leq (r-1) \frac{\varepsilon(t)}{(2t)^2} \leq (r-1) \frac{\varepsilon(0)}{(2t)^2} = (r-1)^2 \frac{\|x_0 - x^*\|^2}{(2t)^2}$$

2.3 Solution de l'EDO

Soit f une fonctionnelle quadratique $f(x) = \frac{1}{2} \langle Ax, x \rangle - \langle b, x \rangle + c$ où $A \in \mathcal{M}_{n,n}$ est une matrice définie positive et qui admet la décomposition suivante : $A = Q^T \Lambda Q$ où Λ est une matrice diagonale de A c'est à dire qui contient les valeurs propres de A sur sa diagonale. Alors l'EDO devient :

$$\begin{cases} X_i'' + \frac{3}{t}X_i' + \lambda_i X_i = 0 \\ X_i(0) = x_0 \\ X_i'(0) = 0 \end{cases}$$

On introduit $Y_i(u) = uX_i(\frac{u}{\sqrt{\lambda_i}})$ qui satisfait :

$$u^2 Y_i'' + u Y_i' + (u^2 - 1) Y_i = 0$$

En effet :

$$Y_i'(u) = X_i(\frac{u}{\sqrt{\lambda_i}}) + \frac{u}{\sqrt{\lambda_i}} X_i'(\frac{u}{\sqrt{\lambda_i}})$$

Et :

$$\begin{aligned} Y_i''(u) &= \frac{1}{\lambda_i} X_i'(\frac{u}{\sqrt{\lambda_i}}) + \frac{1}{\sqrt{\lambda_i}} X_i''(\frac{u}{\sqrt{\lambda_i}}) + \frac{u}{\lambda_i} X_i''(\frac{u}{\sqrt{\lambda_i}}) \\ &= \frac{2}{\sqrt{\lambda_i}} X_i'(\frac{u}{\sqrt{\lambda_i}}) + \frac{u}{\lambda_i} X_i''(\frac{u}{\sqrt{\lambda_i}}) \end{aligned}$$

Donc en remplaçant dans l'EDO qu'on vient de définir :

$$\begin{aligned} u^2 Y_i'' + u Y_i' + (u^2 - 1) Y_i &= \frac{2u^2}{\sqrt{\lambda_i}} X_i'(\frac{u}{\sqrt{\lambda_i}}) + \frac{u^3}{\lambda_i} X_i''(\frac{u}{\sqrt{\lambda_i}}) + u X_i(\frac{u}{\sqrt{\lambda_i}}) \\ &\quad + \frac{u^2}{\sqrt{\lambda_i}} X_i'(\frac{u}{\sqrt{\lambda_i}}) + u^3 X_i(\frac{u}{\sqrt{\lambda_i}}) - u X_i(\frac{u}{\sqrt{\lambda_i}}) \\ &= \frac{u^3}{\lambda_i} X_i''(\frac{u}{\sqrt{\lambda_i}}) + \frac{3u^2}{\sqrt{\lambda_i}} X_i'(\frac{u}{\sqrt{\lambda_i}}) + u^3 X_i(\frac{u}{\sqrt{\lambda_i}}) \\ &= u^2 (\frac{u}{\lambda_i} X_i''(\frac{u}{\sqrt{\lambda_i}}) + \frac{3}{\sqrt{\lambda_i}} X_i'(\frac{u}{\sqrt{\lambda_i}}) + u X_i(\frac{u}{\sqrt{\lambda_i}})) \end{aligned}$$

Remarque : $u^2 Y_i'' + u Y_i' + (u^2 - 1) Y_i = 0$ est une équation différentielle d'ordre 1 de **Bessel**.

Proposition : Son unique solution est définie par la fonction suivante :

$$J_1(u) = \sum_{n=0}^{\infty} \frac{(-1)^n}{(2n)!!(2n+2)!!} u^{2n+1}$$

où $m!! = m \times (m-2) \times \dots \times 2$ si m pair ou $m \times (m-2) \times \dots \times 1$ si m impair.

Preuve : Admise.

Remarque : $\forall t$ suffisamment grand $J_1(t) = \sqrt{\frac{2}{\pi t}} \cos(t - \frac{3\pi}{4}) + \mathcal{O}(\frac{1}{t})$

2.4 Fluctuation d'une fonction fortement convexe

On étend l'EDO à une fonction en dimension 1 fortement convexe. Soit $f \in \mathcal{S}_{\mu,L}$. On suppose que f atteint son min en $x^* = 0$. Alors par définition :

$$\mu \leq \frac{f'(x)}{x} \leq L \quad \forall x \neq 0$$

On note X la solution de l'EDO originale et on considère l'équation auto-adjointe :

$$(t^3 Y')' + \frac{t^3 f'(X(t)) Y}{X(t)} = 0$$

qui admet une solution $Y(t) = X(t)$.

On considère également l'équation $(t^3 Y')' + \mu t^3 Y = 0$. Cette dernière admet une solution $\tilde{Y}(t) = J_1(\sqrt{\mu t})/t$.

On note $\tilde{t}_1 < \tilde{t}_2 < \dots$ toutes les racines de $J_1(t)$ qui satisfont $3,8317 = \tilde{t}_1 - \tilde{t}_0 > \tilde{t}_2 - \tilde{t}_3 > \dots > \pi$ avec $t_0 = 0$.

Donc toutes ces racines positives de $\tilde{Y}$ sont $\tilde{t}_1/\sqrt{\mu}, \dots$ puisque $t^3 \frac{f'(X(t))}{X(t)} \geq \mu t^3$ alors $X(t)$ admet une racine dans chaque intervalle $[\tilde{t}_i/\sqrt{\mu}, \tilde{t}_{i+1}/\sqrt{\mu}]$. On en déduit qu'entre 2 racines positives consécutives, il y a au moins un $\tilde{t}_i/\sqrt{\mu}$. Ce qui prouve que la fréquence des oscillations de f est entre $\mathcal{O}(\mu)$ et $\mathcal{O}(L)$.

2.4.1 La constante 3

Dans cette section, nous allons expliquer dans un premier temps, l'origine de la constante 3 qui apparait dans l'EDO et ensuite nous allons étudier les raisons de ce choix.

On rappelle que le coefficient de momentum du schéma de Nesterov est le suivant : $\frac{k-1}{k+3}$. On établit dans un premier temps son DL :

$$\frac{k-1}{k+3} = 1 - \frac{3}{k} + \mathcal{O}\left(\frac{1}{k^2}\right)$$

d'où l'origine de la constante 3 de l'EDO. En fait, la constante r est le plus petit réel permettant à l'EDO d'atteindre la même vitesse de convergence que le schéma de Nesterov.

A présent, nous allons tenter de généraliser cette EDO en changeant la constante 3 par r quelconque. On considère donc l'EDO suivante :

$$\begin{cases} X'' + \frac{r}{t}X' + \nabla f(X) = 0 \\ X(0) = x_0 \\ X'(0) = 0 \end{cases}$$

On peut donc appliquer le **théorème 3** sur l'existence et unicité de la solution. Alors si $r \geq 3$ alors la vitesse de convergence ne change pas alors que si r est strictement inférieur à 3 alors la vitesse de convergence n'est plus valable.

2.4.2 High friction

Dans cette section, nous allons étudier la vitesse de convergence de cette nouvelle EDO dans le cas où $r \geq 3$ pour $f \in \mathcal{F}_\infty$. Rigoureusement, nous considérons l'énergie suivante :

$$\varepsilon(t) = \frac{2t^2}{r-1} (f(X(t)) - f^*) + (r-1) \|X(t) + \frac{t}{r-1} X'(t) - X^*\|^2$$

Théorème 5 : La solution de l'EDO généralisée satisfait :

$$f(X(t)) - f^* \leq \frac{(r-1)^2 \|x_0 - x^*\|^2}{2t^2}$$

et

$$\int_0^\infty t(f(X(t)) - f^*) dt \leq \frac{(r-1)^2 \|x_0 - x^*\|^2}{2(r-3)}$$

Preuve : On note $tX'' + rX' = -t\nabla f(X)$ et de la même manière que précédemment, on dérive l'énergie afin d'étudier sa monotonie.

$$\begin{aligned}
\varepsilon'(t) &= \frac{4t}{r-1}(f(X(t)) - f^*) + \frac{2t^2}{r-1} \langle \nabla f(X), X' \rangle \\
&\quad + 2 \langle X + \frac{t}{r-1}X' - X^*, tX'' + rX \rangle \\
&= \frac{4t}{r-1}(f(X(t)) - f^*) - 2t \langle X - X^*, \nabla f(X) \rangle \\
&\leq \frac{-2(r-3)t}{r-1}(f(X(t)) - f^*)
\end{aligned}$$

par convexité de f .

Puisque X^* est le minimum de l'EDO alors $f(X) \geq f^*$ donc la partie droite de l'inégalité est négative. Alors $\varepsilon'(t)$ décroît donc :

$$\begin{aligned}
\frac{2t^2}{r-1}(f(X(t)) - f^*) &\leq \varepsilon(t) \leq \varepsilon(0) = (r-1)\|x_0 - x^*\|^2 \\
\Leftrightarrow f(X(t)) - f^* &\leq \frac{(r-1)^2\|x_0 - x^*\|^2}{2t^2}
\end{aligned}$$

De plus,

$$\begin{aligned}
\int_0^\infty \frac{-2(r-3)t}{r-1}(f(X(t)) - f^*) &\leq \int_0^\infty \varepsilon'(t)dt \\
\Leftrightarrow \int_0^\infty \frac{2(r-3)t}{r-1}(f(X(t)) - f^*) &\leq \int_0^\infty -\varepsilon'(t) \\
&= \varepsilon(0) - \varepsilon(\infty) = (r-1)\|x_0 - x^*\|^2 \\
\Leftrightarrow \int_0^\infty t f(X(t)) - f^* &\leq \frac{(r-1)^2\|x_0 - x^*\|^2}{2(r-3)}
\end{aligned}$$

On en déduit donc que pour un $r \geq 3$, des frottements élevés autour du minimum apparaissent et que la vitesse de convergence de l'EDO n'augmente pas. Donc augmenter la constante r n'est pas nécessaire.

2.4.3 Low Frictions

A présent, nous allons nous intéresser au cas où $r < 3$. Nous ne pouvons plus utiliser l'énergie défini auparavant car nous obtenons l'inégalité :

$$\frac{-2(r-3)t}{r-1}(f(X(t)) - f^*) > 0$$

Nous allons donc trouver un contre-exemple qui ne vérifie pas une vitesse de convergence de l'ordre de $\mathcal{O}(\frac{1}{t^2})$.

Soit $f(X) = \frac{1}{2}\|X\|^2$ et X la solution qui vérifie l'EDO généralisée. Soit $Y = t^{\frac{r-1}{2}}X$ satisfait :

$$t^2 Y'' + t Y' + (t^2 - \frac{(r-1)^2}{4}) Y = 0.$$

La solution de cette équation s'approxime de la manière suivante : $Y(t) \approx t^{\frac{r-1}{2}} x_0$ pour t suffisamment petit. Ainsi, la solution de l'équation de Bessel sous forme vectorielle à l'ordre $\frac{r-1}{2}$ est :

$$Y(t) = 2^{\frac{r-1}{2}} \Gamma(\frac{r-1}{2}) J_{\frac{r-1}{2}}(t) x_0$$

où $J_{\frac{r-1}{2}}(t) = \sqrt{\frac{2}{\pi t}} (\cos(t - \frac{(r-1)\pi}{4} - \frac{\pi}{4}) + \mathcal{O}(\frac{1}{t}))$.

Pour t assez grand, alors $f(X(t)) - f^* = \mathcal{O}(\frac{\|x_0 - x^*\|^2}{t^r})$. Donc l'EDO généralisée avec $r < 2$ ne peut pas atteindre $\mathcal{O}(\frac{1}{t^2})$.

Nous revenons à la fin de la preuve du Théorème 1 : On considère à présent $2 \leq \alpha \leq 4$. On applique le théorème suivant :

Théorème : La solution de l'EDO généralisée satisfait

$$f(X(t)) - f^* \leq \frac{(r-1)^2 \|X_0 - x^*\|^2}{2t^2}$$

et

$$\int_0^\infty t(f(X(t)) - f^*) dt \leq \frac{(r-1)^2 \|X_0 - x^*\|^2}{2(r-3)}$$

Alors on obtient une borne supérieure pour $\varepsilon(t)$:

$$\varepsilon(t_\alpha) + A_\alpha \|x_0 - x^*\|^2 \leq \varepsilon(t_\alpha) + A_\alpha \|x_0 - x^*\|^2.$$

avec

$$A_\alpha = \frac{(\alpha-2)(r-1)^2(2r-\alpha)}{8\mu t^{4-\alpha}}$$

On borne $\varepsilon(t_\alpha)$:

$$\begin{aligned} \varepsilon(t_\alpha) &\leq t_\alpha^\alpha (f(X(t_\alpha)) - f^*) + B_\alpha \left\| \frac{2r-2}{2r-\alpha} X(t_\alpha) + \frac{2t_\alpha}{2r-\alpha} \dot{X}(t_\alpha) - \frac{2r-2}{2r-\alpha} x^* \right\|^2 \\ &\quad + B_\alpha \left\| \frac{\alpha-2}{2r-\alpha} X(t_\alpha) - \frac{\alpha-2}{2r-\alpha} x^* \right\|^2. \end{aligned}$$

avec

$$B_\alpha = \frac{(2r - \alpha)^2 t_\alpha^{\alpha-2}}{4}$$

par décroissance de l'énergie :

$$\varepsilon(t_\alpha) \leq (r - 1)^2 t_\alpha^{\alpha-2} \|x_0 - x^*\|^2 + \frac{(\alpha - 2)^2 (r - 1)^2}{4\mu t_\alpha^{4-\alpha}} \|x_0 - x^*\|^2$$

En combinant (25) et (26) on a :

$$\begin{aligned} \varepsilon(t) &\leq (r - 1)^2 t_\alpha^{\alpha-2} \|x_0 - x^*\|^2 + \frac{(\alpha - 2)(r - 1)^2}{8\mu t_\alpha^{4-\alpha}} \|x_0 - x^*\|^2 \\ &= \mathcal{O}\left(\frac{\|x_0 - x^*\|^2}{\mu^{(\alpha-2)/2}}\right) \end{aligned}$$

Pour $t \geq t_\alpha$ il suffit d'appliquer $f(X(t)) - f^* \leq \frac{\varepsilon(t)}{t^3}$.

Pour $t < t_\alpha$, par le **Théorème 5** on sait que $f(X(t)) - f^*$ est borné supérieurement par :

$$\begin{aligned} \frac{(r - 1)^2 \|x_0 - x^*\|^2}{2t^2} &\leq \frac{(r - 1)^2 \mu^{(\alpha-2)/2} [(\alpha - 2)(2r - \alpha)2\mu]^{(\alpha-2)/2}}{2} \frac{\|x_0 - x^*\|^2}{\mu^{(\alpha-2)/2} t^\alpha} \\ &= \mathcal{O}\left(\frac{\|x_0 - x^*\|^2}{\mu^{(\alpha-2)/2} t^\alpha}\right) \end{aligned}$$

Le théorème est valide pour $\tilde{\alpha} > 2$: On va donc montrer que le théorème reste valide pour $\alpha > \tilde{\alpha} + 1$.

Si $r \geq \frac{3\alpha}{2}$, alors on a :

$$\begin{aligned} \varepsilon(t) &\leq \varepsilon(t_\alpha) + \frac{(\alpha - 2)(2r - \alpha)t^{\alpha-2}}{4\mu} \frac{\tilde{C}\|x_0 - x^*\|^2}{\mu^{(\alpha-2)/2} t^{\tilde{\alpha}}} \\ &\leq \varepsilon(t_\alpha) + \frac{(\alpha - 2)(2r - \alpha)}{4\mu} \frac{\tilde{C}\|x_0 - x^*\|^2}{\mu^{(\alpha-2)/2} t_\alpha} \end{aligned}$$

car $t^{\alpha-2}/t^{\tilde{\alpha}} = t^{\alpha-2}/t^{\alpha-1} = t^{\alpha-2-\alpha+1} = 1/t$ et $\tilde{C}$ dépend de $\tilde{\alpha}$ et de r .

Alors :

$$\begin{aligned}
\varepsilon(t) &\leq (r-1)^2 t_\alpha^{\alpha-2} \|x_0 - x^*\|^2 + \frac{(\alpha-2)^2 (r-1)^2}{4\mu t_\alpha^{4-\alpha}} \|x_0 - x^*\|^2 \\
&\quad + \frac{\tilde{C}(\alpha-2)(2r-\alpha)}{4\mu^{(\alpha-1)/2} t_\alpha} \|x_0 - x^*\|^2 \\
&= \mathcal{O}\left(\frac{\|x_0 - x^*\|^2}{\mu^{(\alpha-2)/2}}\right)
\end{aligned}$$

et on retrouve bien le résultat attendu.

Remarque : Puisque C dépend de r , si on augmente r alors on augmente C . Donc augmenter r n'impliquerait pas forcément une meilleure limite d'erreur. On souhaite obtenir une vitesse de convergence de l'ordre de $\mathcal{O}(\frac{1}{k^\alpha})$.

3 Simulations Numériques.

Les premières sections nous ont permis de mieux comprendre l'algorithme de Nesterov et le principe de sa modélisation par une équation différentielle du second ordre. A présent, nous allons donc illustrer ce qu'on vient de démontrer à travers des graphiques générés en Python. Tout d'abord nous présentons les pseudos-codes de l'algorithme de Nesterov et du schéma de Euler de l'EDO.

3.1 Pseudos codes

```
fonction descente_nesterov(grad_f, x0, s, eps):
    x = x0
    y = x0

    initialiser x\_list et y\_list comme
    des matrices vides de dimensions 2 x 0

    ajouter x à x\_list
    ajouter y à y\_list

    x = x0 - s * grad\_f(x0)
    y = x

    ajouter x à x\_list
    ajouter y à y\_list

    i = 2

    tant que la norme de grad\_f(x) > eps:
        x = y\_list[:, i-1] - 0.5 * grad\_f(y\_list[:, i-1])
        ajouter x à x\_list

        y = x\_list[:, i] + ((i-1)/(i+2)) * (x\_list[:, i] - x\_list[:, i-1])
        ajouter y à y\_list

        i = i + 1

    retourner i, x\_list, y\_list
```

Cet algorithme n'est pas très coûteux puisqu'il fonctionne seulement avec le gradient de f et non pas avec sa hessienne comme le ferait l'algorithme de Newton par exemple.

```

fonction euler_explicite(u0, h, T, A, b, r):
  t <- h
  t_sol <- tableau vide
  ajouter t à t_sol

  u1 <- A @ u0 - b
  U0 <- concaténer(u0, u1)
  U <- U0
  U_list <- U0

  b1 <- vecteur nul de taille 2
  B <- concaténer(b1, b)

  tant que t < T faire:
    M <- [[0, 0, 1, 0],
           [0, 0, 0, 1],
           [-4*10-2, 0, -r/t, 0],
           [0, -10*10-3, 0, -r/t]]

    U <- U + h * (M @ U - B)
    ajouter U à U_list
    t <- t + h
    ajouter t à t_sol

  retourner U_list

```

3.2 Exemples numériques

Soit $f(x_1, x_2) = 2 \times 10^{-2}x_1^2 + 5 \times 10^{-3}x_2^2$ une fonctionnelle quadratique de dimension 2.

Alors f peut s'écrire sous la forme $f(x) = \frac{1}{2}\langle Ax, x \rangle - \langle b, x \rangle + c$ où A s'écrit :

$$\begin{pmatrix} 4 \times 0,01 & 0 \\ 0 & 10 \times 0,001 \end{pmatrix}$$

et b est le vecteur nul de dimension 2 et $c = 0$.




FIGURE 1 – Schéma de Nesterov appliqué à f .




FIGURE 2 – Schéma de Euler appliqué à l'EDO pour f en fonction de r .




FIGURE 3 – Schéma de Euler explicite appliquée à l'EDO pour f pour $h = 0.25$ en fonction de r .




FIGURE 4 – Comparaison entre le schéma de Nesterov, l'EDO et sa solution pour $h = 0.1$ et $h = 0.5$




FIGURE 5 – Schéma de Euler explicite appliquée à l'EDO pour f en fonction de r .

Interprétation : La fonctionnelle quadratique converge vers le minimum 0 comme le montre le schéma de Nesterov sur la **Figure 1**. Sa convergence dépend notamment du pas que l'on choisit. Bien que sur la figure, les courbes convergent toutes, on observe qu'elles prennent tout de même une trajectoire légèrement différente. On en déduit donc que plus le pas est petit, plus la convergence de l'algorithme sera meilleure. Sur la seconde et troisième figure, nous observons que la convergence de l'EDO dépend presque exclusivement de la constante r choisie. En effet, pour un $r < 3$, il paraît compliqué de s'approcher tout de suite du 0, minimum de la fonction, contrairement au cas où $r > 3$, qui s'approchent de 0 sans grande difficulté avec beaucoup moins d'itérés. Quant au cas $r = 3$, il semble converger le plus 'proprement'. Ce qui illustre bien le choix du $r = 3$ par les chercheurs. De plus, la quatrième figure permet de mettre en lumière la ressemblance des convergences du schéma de Nesterov avec le schéma de Euler. Enfin, sur la dernière figure, un fait intéressant est mis en avant : en effet, le choix de toujours prendre un pas très petit ne permet pas forcément une meilleure convergence. Ici, on observe bien que l'erreur du schéma de Euler est minimale lorsque $h = 0.25$ et non pas $h = 0.05$.

Conclusion

Nous avons étudié à travers ce mémoire le comportement du célèbre algorithme de Nesterov grâce à une équation différentielle du second ordre. En effet, ceux qui l'avantage par rapport aux autres méthodes de descente du premier ordre sont sa vitesse de convergence et son faible coût d'implémentation. C'est pourquoi, il est utilisé dans de nombreux domaines tels que le machine learning, le transport optimal ou encore la Vision par Ordinateur.

Bibliographie

- A differential equation for modeling Nesterov's Accelerated Gradient Method By Weijie Su, Stephen Boyd and Emmanuel J. Candès
- Convex Optimization by S. Boyd and L. Vandenberghe
- Optimisation sans contraintes par M.Denoyelle
- Convex Optimization : Introductory Course by Mikhail Moklyachuk
- Optimization : Insights and Applications by Jan Brinkhuis and Vladimir Tikhomirov
- Chapitre sur les Méthodes numériques par M.Crauste (cf semestre 1)
- Analyse d'algorithmes de type Nesterov et leurs applications à l'imagerie numérique par Catherine Simard