

Estimation dans un problème inverse linéaire à variables cachées

Vraisemblance, Algorithme EM et Analyse de l'Erreur

Mise en place du problème et Modélisation

Le Contexte Physique : La Cryo-EM

Principe de la Cryo-Microscopie Électronique

- ▶ Des milliers de macromolécules figées dans de la glace amorphe.
- ▶ Le faisceau d'électrons capture des **projections 2D**.
- ▶ **Le problème majeur** : L'orientation tridimensionnelle sous laquelle chaque photo est prise est **inconnue**.
- ▶ Le signal observé est noyé dans un niveau de bruit extrême ($RSB \ll 1$).

[**figures/cryo-Singer.pdf**]
Schéma Cryo-EM / Projections

Le Modèle Mathématique Général

Pour chaque observation $i \in \{1, \dots, n\}$, on formule l'équation :

$$Y_i = A_{Z_i} \theta + \sigma E_i$$

- ▶ $\theta \in \mathbf{E}$: Le paramètre ou signal d'intérêt **inconnu** à estimer ($\dim E = d$).
- ▶ $\mathbf{Z}_i \in \mathcal{Z}$: La **variable cachée** (la transformation géométrique subie par l'objet), supposée i.i.d. selon une loi connue f_Z .
- ▶ $\mathbf{A}_{\mathbf{Z}_i}$: L'opérateur linéaire modélisant la transformation (translation, rotation, projection).
- ▶ $\mathbf{E}_i \sim \mathcal{N}(\mathbf{0}, \text{Id}_p)$: Un bruit blanc gaussien i.i.d., indépendant de Z_i .
- ▶ $\sigma > 0$: Le niveau de bruit de l'appareil de mesure.

Le Cas d'Application Linéaire 1D

Modèle Jouet : Décalages circulaires (Translations sur le Tore)

- ▶ θ est un signal périodique modélisé dans la base de Fourier.
- ▶ Les variables cachées Z_i représentent des translations uniformes sur la grille discretisée.
- ▶ L'opérateur A_{Z_i} applique un déphasage en fréquences.

Piège Statistique : La moyenne empirique brute $\frac{1}{n} \sum Y_i$ converge vers un signal plat.
L'information de phase s'efface !

[figures/signaux₁D.pdf]
Signaux simulés tradatés

Méthodes d'Estimation Numérique

Le Défi de la Log-Vraisemblance Marginale

Puisque les variables Z_i sont manquantes, on doit intégrer (marginaliser) la densité conjointe :

$$l_n(\theta) = \sum_{i=1}^n \log \left(\int_{\mathcal{Z}} f_Y(Y_i | Z = z, \theta) f_Z(z) d\mu(z) \right)$$

Une structure non linéaire complexe (Log-Sum-Exp) :

- ▶ $l_n(\theta)$ **n'est plus concave**, invalidant une optimisation exacte globale directe.
- ▶ Présence de multiples **maximums locaux** (pièges pour les algorithmes).
- ▶ **Défaut d'identifiabilité** : Le problème est invariant à une translation globale près.
On doit introduire une **distance quotient d'orbite** :

$$\tau \quad (0, \theta^*) \quad \cdot \quad \|\theta\| \quad \Delta \quad \theta^* \|\cdot\|$$

Descente de Gradient Directe vs Approche EM

Pour maximiser $l_n(\theta)$, deux choix algorithmiques s'opposent :

- ▶ Calcul direct du gradient de la log-vraisemblance marginale.
- ▶ Fait intervenir les poids a posteriori $w_{i,z}(\theta)$.
- ▶ Sensible au choix du pas (Règle d'Armijo nécessaire).
- ▶ Nécessite des stratégies multi-départs pour échapper aux extrema locaux.

- ▶ Maximise une borne inférieure via les **données complètes** (Y, Z) .
- ▶ Propriété de **croissance monotone** de la vraisemblance à chaque étape.
- ▶ Découple la complexité : l'étape d'inversion redevient quadratique et linéaire.

Les Deux Étapes Clés de l'Algorithme EM

À l'itération k , on calcule l'estimation récursive $\theta^{(k+1)}$:

Étape E (Espérance) : Calcul des probabilités a posteriori (*poids*) pour chaque échantillon i et transformation z :

$$w_{i,z}(\theta^{(k)}) = \frac{f_Z(z) \exp\left(-\frac{\|Y_i - A_z \theta^{(k)}\|^2}{2\sigma^2}\right)}{\int_{\mathcal{Z}} f_Z(z') \exp\left(-\frac{\|Y_i - A_{z'} \theta^{(k)}\|^2}{2\sigma^2}\right) d\mu(z')}$$

Étape M (Maximisation) : Résolution d'un point fixe sous forme de système linéaire :

$$\left(\sum_{i=1}^n \int_{\mathcal{Z}} w_{i,z}(\theta^{(k)}) A_z^\top A_z d\mu(z) \right) \theta^{(k+1)} = \sum_{i=1}^n \int_{\mathcal{Z}} w_{i,z}(\theta^{(k)}) A_z^\top Y_i d\mu(z)$$

L'étape M est un problème **quadratique convexe**, trivial à résoudre numériquement.

Analyse Spectrale et Régularisation

Le Problème Inverse Mal Posé en Dimension Supérieure

La Rupture Géométrique (Cas 2D / Radon)

- ▶ En projection 2D, l'opérateur A_z lisse intensément le signal.
- ▶ Le spectre de l'opérateur décroît en $|\xi|^{-1}$ (Théorème de la tranche de Fourier).
- ▶ La matrice de l'étape M devient **très mal conditionnée** (valeurs propres proches de 0).
- ▶ **Conséquence** : Le bruit de mesure σE_i est multiplié par $1/\lambda_k$ et explose en haute fréquence.

[figures/spectre $_A^T A.pdf$]
Évanouissement des valeurs propres

Stratégies de Stabilisation : Tikhonov et Pénalités

Pour stabiliser le système, on modifie la fonction objectif en ajoutant une pénalité :

$$l_n^{\text{reg}}(\theta) = l_n(\theta) - \lambda \mathcal{R}(\theta)$$

- ▶ **Régularisation de Tikhonov (L^2)** : $\mathcal{R}(\theta) = \frac{1}{2}\|\theta\|_2^2$.
 - Décale artificiellement les valeurs propres de la matrice : $\lambda_j \leftarrow \lambda_j + \lambda\sigma^2$.
 - Empêche l'inversion de diviser par zéro, supprimant les oscillations hautes fréquences.
- ▶ **Régularisation Lasso (L^1)** : $\mathcal{R}(\theta) = \|\theta\|_1 \implies$ Favorise des solutions parcimonieuses (creuses).
- ▶ **Variation Totale (TV)** : $\mathcal{R}(\theta) = \|\nabla\theta\|_1 \implies$ Préserve les contours et les zones homogènes (adapté au cas 2D).

[[erreur_vslambda.pdf](#)]

Compromis biais-variance sur λ

[[reconstruction_2d.pdf](#)]

Impact de la TV en 2D

L'indispensable compromis : Si λ est trop faible, le bruit submerge l'image. Si λ est trop fort, les détails structuraux fins s'estompent (biais élevé).

La quantité de données ($n \rightarrow \infty$) réduit l'erreur de variance, mais seule la pénalisation mathématique structurelle gère le caractère mal posé de la physique (Radon 2D).

Ouverture : Généralisation en 3D (espace des rotations non commutatif $SO(3)$) et traitement des hétérogénéités de distribution de f_Z .

Merci pour votre attention

Place aux questions